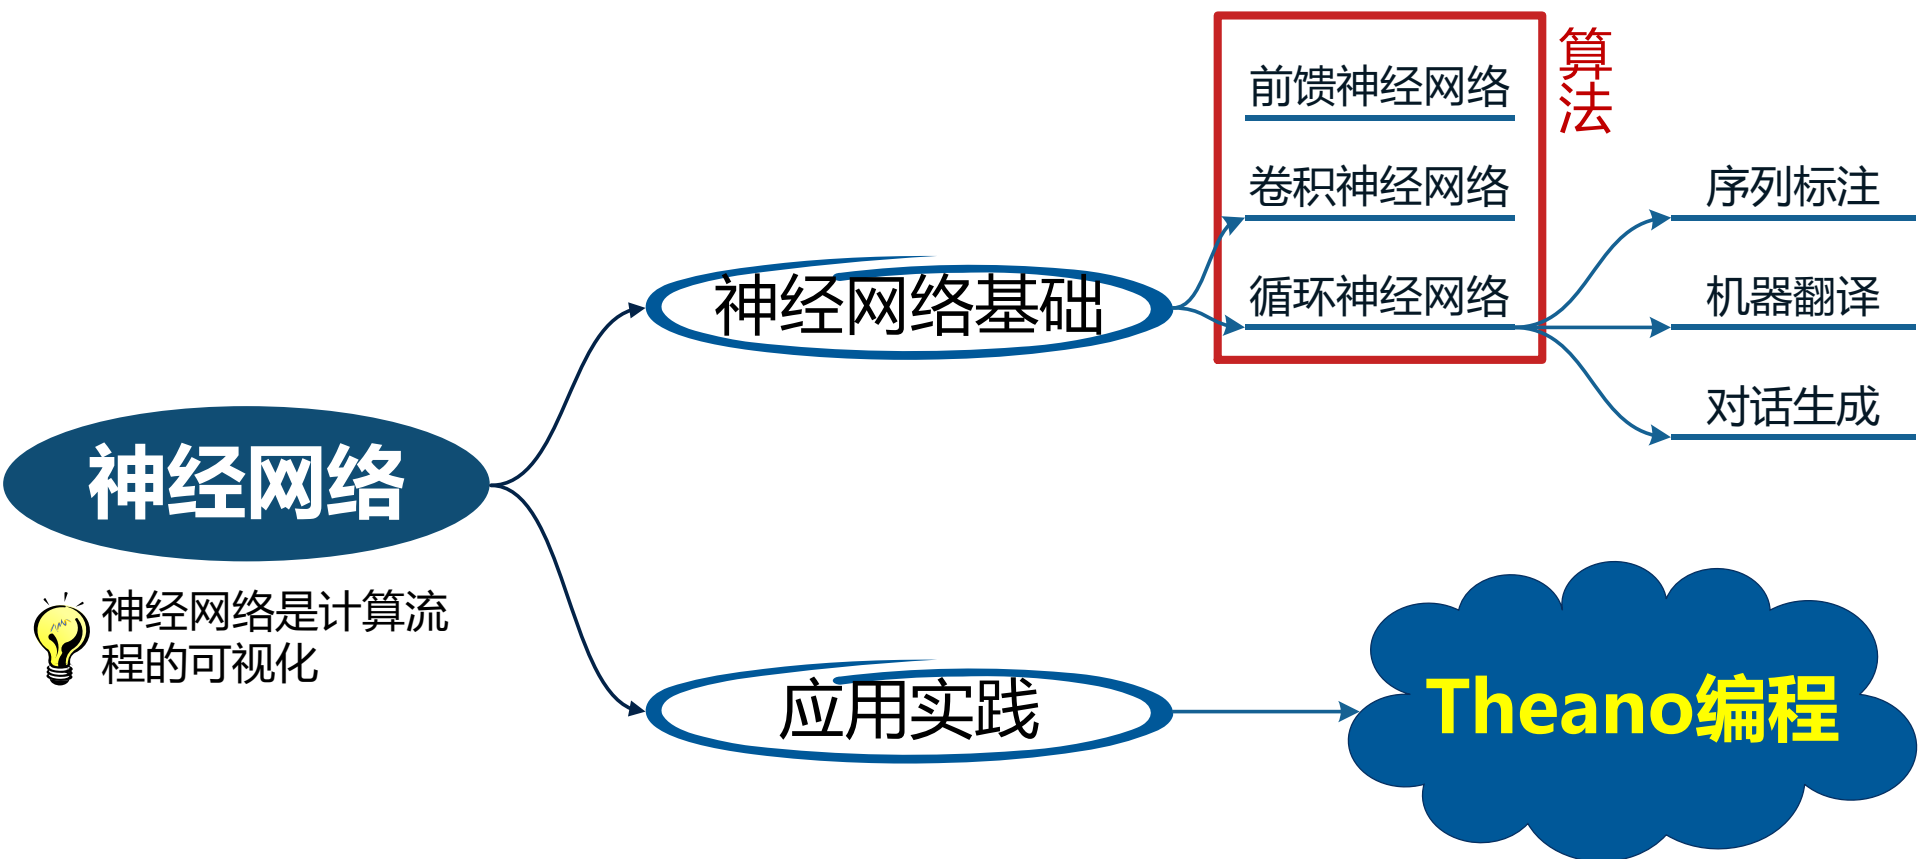


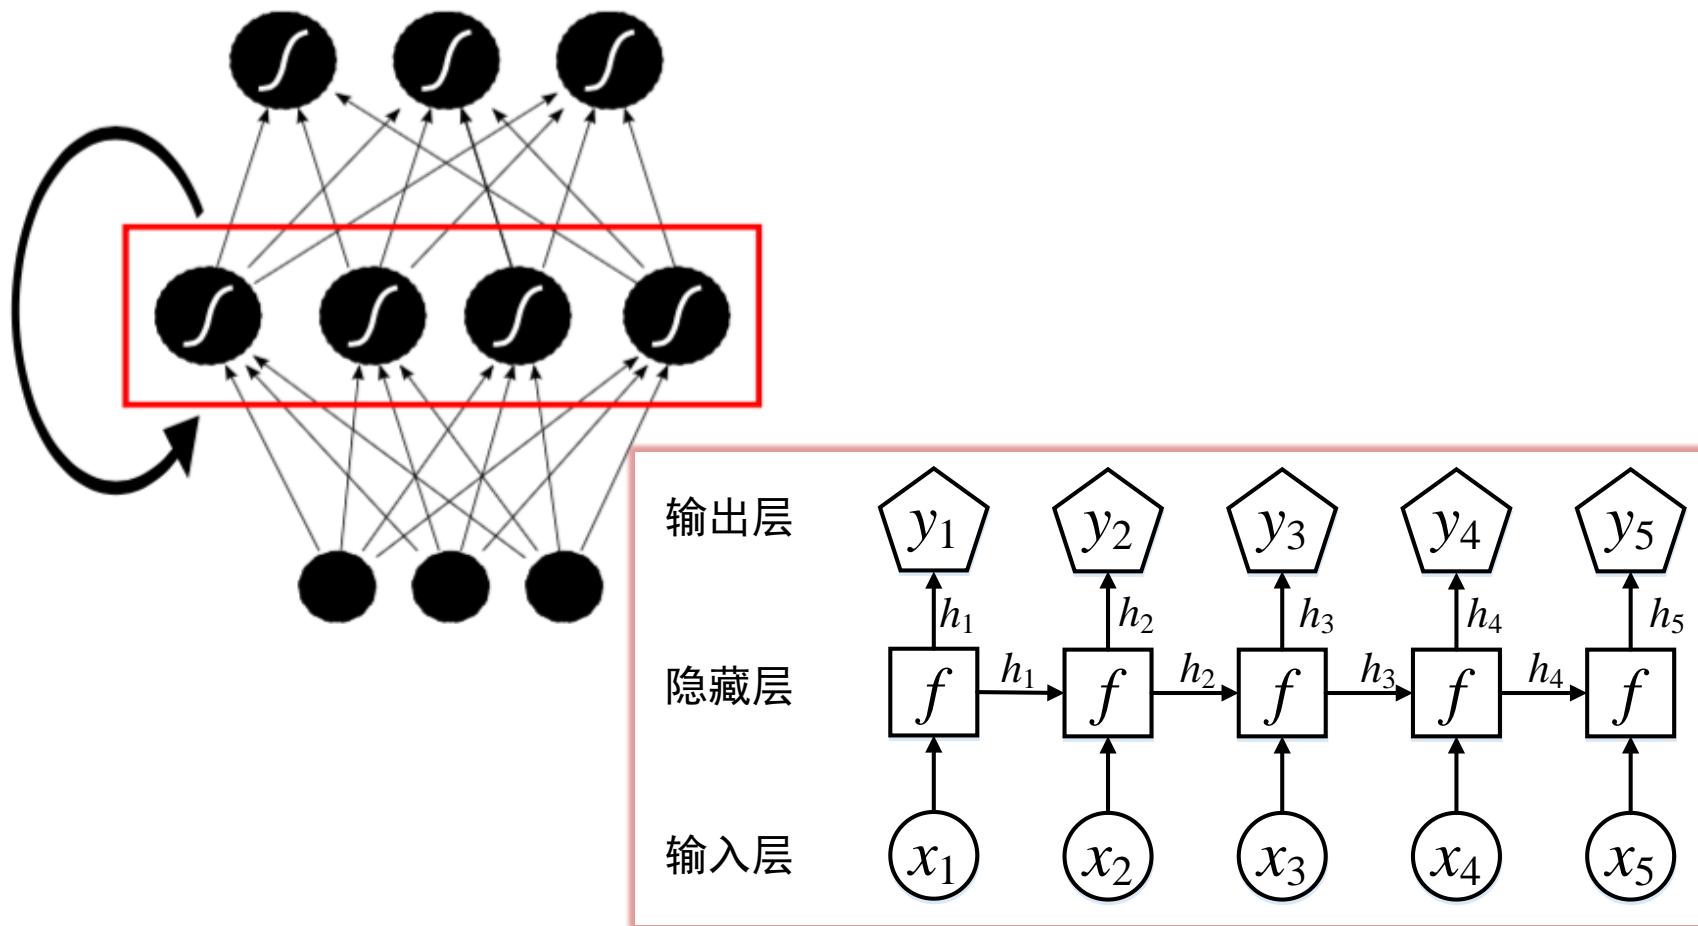
课程专题三：神经网络方法



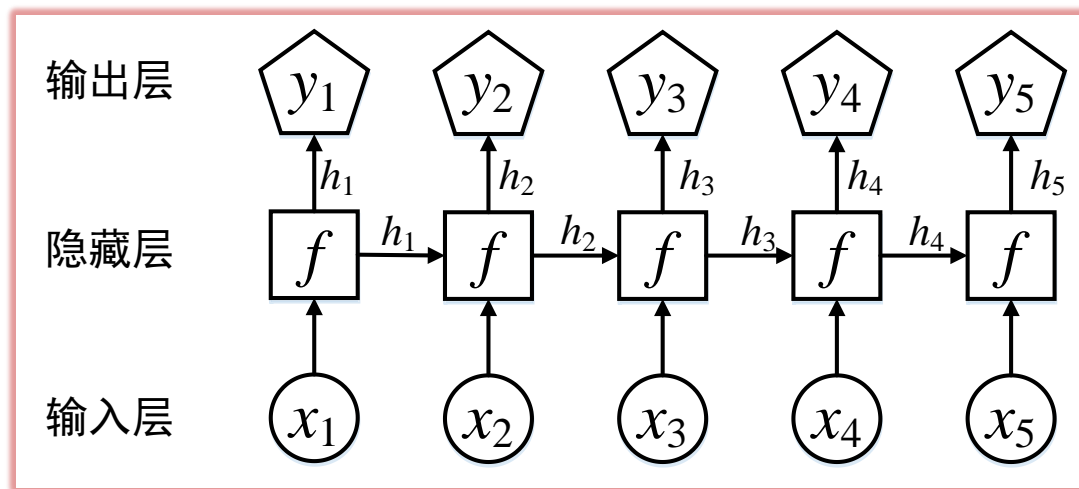
RNN模型介绍

- 神经网络模型中，普遍认为网络的连接参数，蕴含的是“知识”，它像大脑神经元之间的连接，类似的数据重新输入后，经过这些参数的转换，可以复现类似的结论。
- RNN可以学习序列数据，并可以根据上下文复现学习到的序列。

RNN到底长什么样？



RNN建模



$$p(y_1, y_2, \dots, y_T \mid x_1, x_2, \dots, x_T) = \prod_i p(y_i \mid Y_{<i}, X_{\leq i})$$


$$h_i = f(x_i, h_{i-1}) \quad h_0 = 0 \text{ 作为初始输入}$$

$$p(y_i \mid Y_{<i}, X_{\leq i}) = \text{softmax}(h_i)$$

h_i 试图包含了 $(Y_{<i}, X_{\leq i})$ 中的所有信息


RNN应用介绍

- **序列标注 (Sequential Labeling)** : 语言模型, 建模某句话用某种语言生成的概率




RNN应用介绍

- 序列标注: POS (Part of Speech) 标注、分词

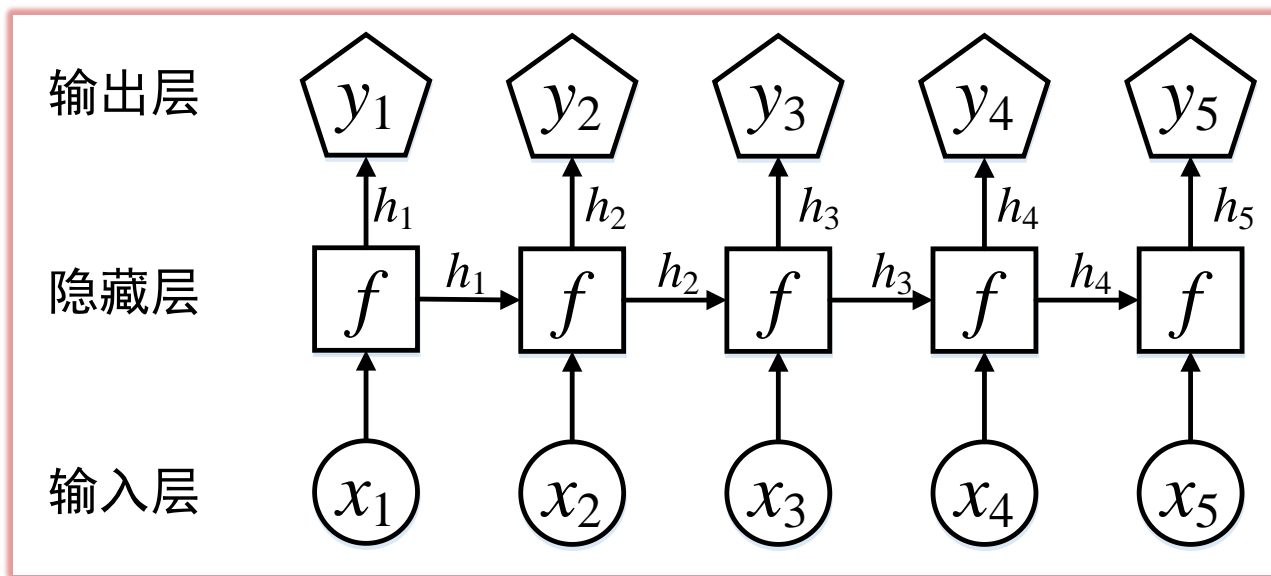


POS



分词

RNN的特点



- 每个时刻的输入数据，与上一时刻输出数据，合并生成当前时刻的输出数据
- 方框部分代表神经元，所有时刻的数据都共享同一组神经元参数

RNN建模

$$p(y_1, y_2, \dots, y_T \mid x_1, x_2, \dots, x_T) = \prod_i p(y_i \mid Y_{<i}, X_{\leq i})$$

$$h_i = f(x_i, h_{i-1})$$

$$p(y_i \mid Y_{<i}, X_{\leq i}) = \text{softmax}(h_i)$$

- 关键点

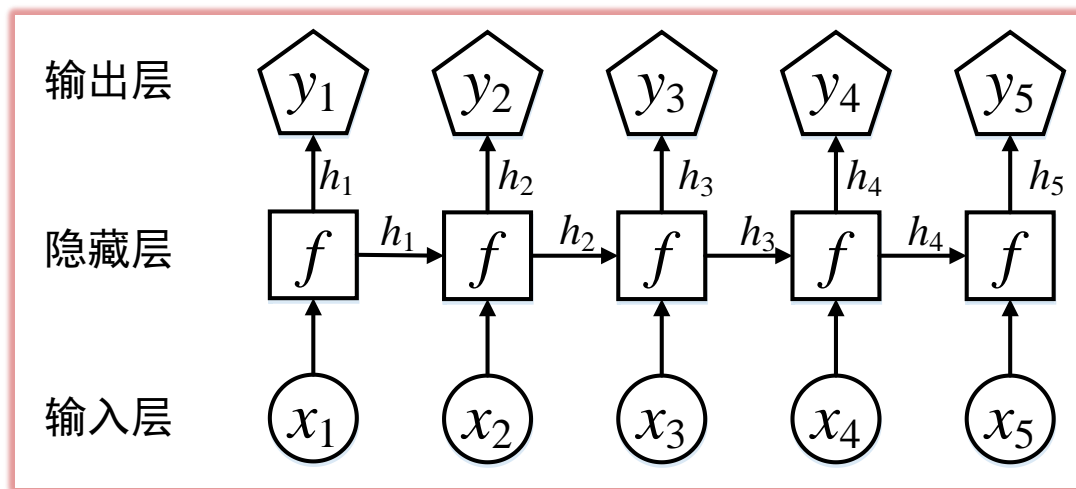
- 研究 f 函数如何建模

- 研究 x_i 如何表达

- x_i 对应该词的词向量 (Embedding)

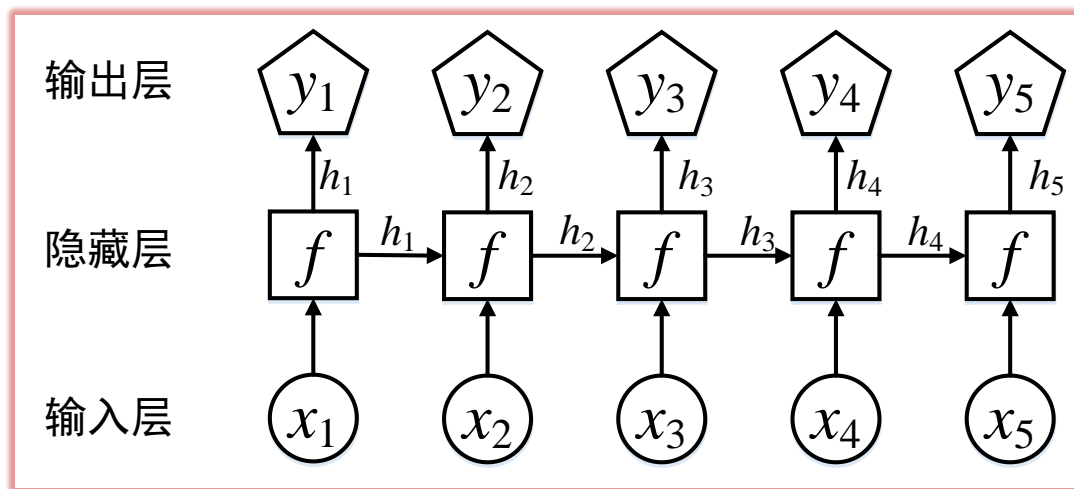
$$W_{k \times n} \cdot \begin{pmatrix} 0 \\ \vdots \\ 1 \\ \vdots \\ 0 \end{pmatrix} = x$$

朴素的 f 函数：RNN的正向计算



- 令 $z_i = Uh_{i-1} + Wx_i + b$ U和W的简单含义
- $h_i = \sigma(z_i)$
- 网络对每个时刻都有输出值 \hat{y}_i
- 计算 h_i 可以是简单激活函数，如sigmoid, tanh等；也可以是复杂的多层神经网络。

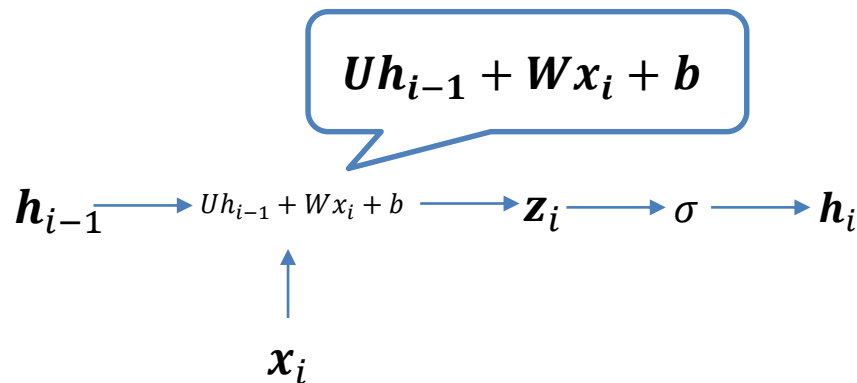
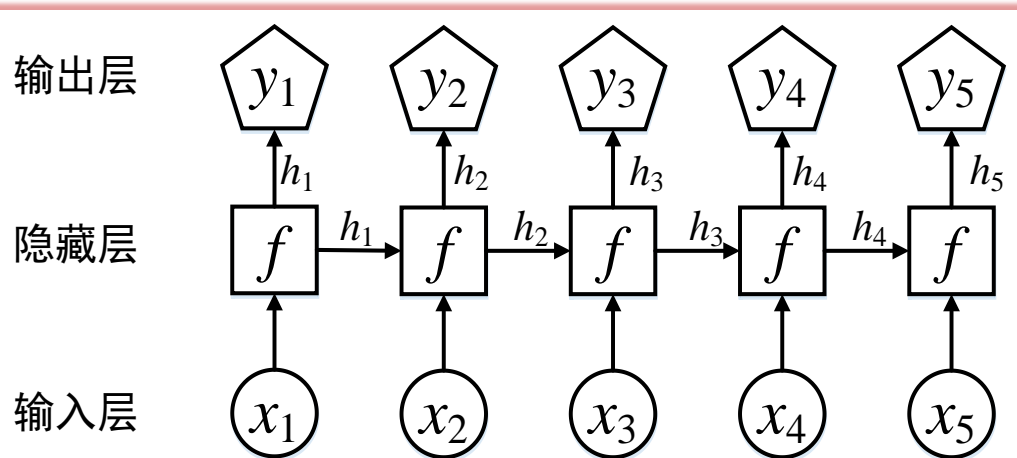
网络代价函数



其代价函数可以是平方误差，在**一个序列**上的代价函数表示为

$$C = \sum_i \frac{1}{2} \|\hat{y}_i - y_i\|^2$$

误差反向传播



不妨假设总共有 T 个时间步。我们令 $\delta_i = \frac{\partial C}{\partial z_i} = \frac{\partial C_{\geq i}}{\partial z_i}$ ，且 C_i 代表 y_i 对应的误差，则：

$$\delta_i = \frac{\partial C_i}{\partial \mathbf{h}_i} \frac{\partial \mathbf{h}_i}{\partial \mathbf{z}_i} + \frac{\partial C_{>i}}{\partial \mathbf{z}_{i+1}} \frac{\partial \mathbf{z}_{i+1}}{\partial \mathbf{z}_i} = \frac{\partial C_i}{\partial \mathbf{h}_i} \odot \sigma'(\mathbf{z}_i) + \delta_{i+1} \odot (U \sigma'(\mathbf{z}_i))$$

对 f 中的某个参数 θ ，其导数为 $\frac{\partial C}{\partial \theta} = \sum_i \frac{\partial C}{\partial z_i} \frac{\partial z_i}{\partial \theta} = \sum_i \delta_i \frac{\partial z_i}{\partial \theta}$

$\frac{\partial C_i}{\partial \mathbf{h}_i}, \frac{\partial z_i}{\partial \theta}$ 以及求取其他参数的技巧与全连接神经网络相同，这里不再列举。

注：RNN训练方法有很多种，这里只是列出其中一种。

多元复合函数求导法则

- $C = f(z_1(\theta), z_2(\theta), \dots, z_T(\theta))$
- $\frac{\partial C}{\partial \theta} = \sum_i \frac{\partial C}{\partial z_i} \frac{\partial z_i}{\partial \theta} = \sum_i \delta_i \frac{\partial z_i}{\partial \theta}$

f 函数: Long Short Term Memory (LSTM)

f



LSTM是最常用的一种RNN激活函数，
包含输出门 o 、遗忘门 f 和输入门 i 。
它的定义很复杂，如下式：

$$\mathbf{i}_t = \sigma(\mathbf{W}_{wi}\mathbf{w}_t + \mathbf{W}_{hi}\mathbf{h}_{t-1}) \quad (1)$$


$$\mathbf{f}_t = \sigma(\mathbf{W}_{wf}\mathbf{w}_t + \mathbf{W}_{hf}\mathbf{h}_{t-1}) \quad (2)$$

$$\mathbf{o}_t = \sigma(\mathbf{W}_{wo}\mathbf{w}_t + \mathbf{W}_{ho}\mathbf{h}_{t-1}) \quad (3)$$

$$\hat{\mathbf{c}}_t = \tanh(\mathbf{W}_{wc}\mathbf{w}_t + \mathbf{W}_{hc}\mathbf{h}_{t-1}) \quad (4)$$


$$\mathbf{c}_t = \mathbf{f}_t \odot \mathbf{c}_{t-1} + \mathbf{i}_t \odot \hat{\mathbf{c}}_t \quad (5)$$

$$\mathbf{h}_t = \mathbf{o}_t \odot \tanh(\mathbf{c}_t) \quad (6)$$



f 函数: Gated Recurrent Unit (GRU)

f



GRU包含更新门 z 和重置门 r , 如下式:

$$\mathbf{r}_t = \sigma(\mathbf{W}_{wr}\mathbf{w}_t + \mathbf{W}_{hr}\mathbf{h}_{t-1})$$

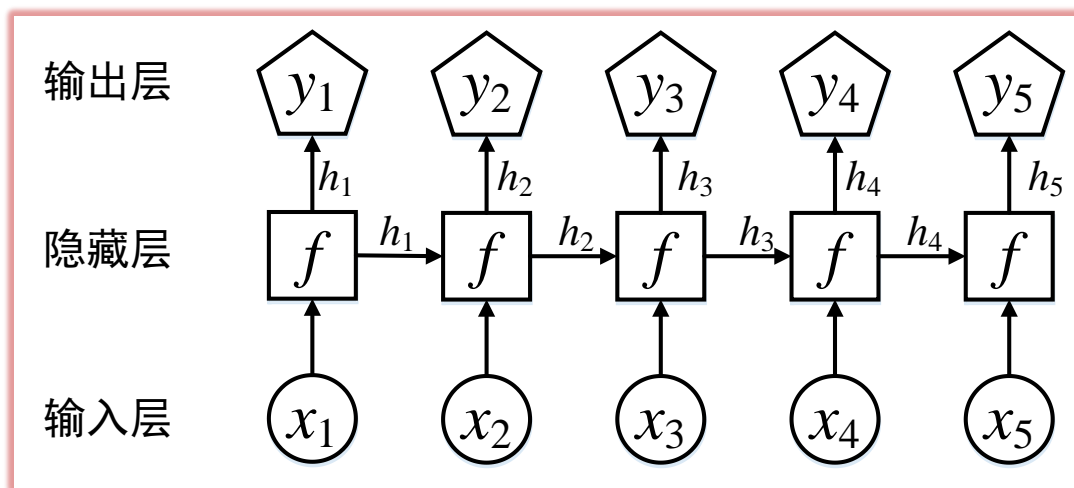
$$\mathbf{z}_t = \sigma(\mathbf{W}_{wz}\mathbf{w}_t + \mathbf{W}_{hz}\mathbf{h}_{t-1})$$

$$\tilde{\mathbf{h}}_t = \sigma(\mathbf{W}_{wr}\mathbf{w}_t + \mathbf{U}(\mathbf{r}_t \odot \mathbf{h}_{t-1}))$$

$$\mathbf{h}_t = \mathbf{z}_t \odot \mathbf{h}_{t-1} + (1 - \mathbf{z}_t) \odot \tilde{\mathbf{h}}_t$$

RNN总结

- 对“序列”进行建模，解决序列标注等实际问题



$$p(y_1, y_2, \dots, y_T \mid x_1, x_2, \dots, x_T) = \prod_i p(y_i \mid Y_{<i}, X_{\leq i})$$

$$h_i = f(x_i, h_{i-1}) \quad h_0 = 0 \text{ 作为初始输入}$$

$$p(y_i \mid Y_{<i}, X_{\leq i}) = \text{softmax}(h_i)$$

f 函数使用**LSTM**, h_i 试图包含了 $(Y_{<i}, X_{\leq i})$ 中的所有信息

作业

- 阅读RNN解决实际问题的示例代码
 - <http://deeplearning.net/tutorial/lstm.html>
- 更多有用的材料
 - <http://karpathy.github.io/2015/05/21/rnn-effectiveness/>
 - <http://colah.github.io/posts/2015-08-Understanding-LSTMs/>

谢谢！