


● 两类问题的判别函数（以二维模式样本为例）

若 \mathbf{x} 是二维模式样本 $\mathbf{x} = (x_1 \ x_2)^T$ ，用 x_1 和 x_2 作为坐标分量，得到模式的平面图：



这时，若这些分属于 ω_1 和 ω_2 两类的模式可用一个直线方程 $d(\mathbf{x})=0$ 来划分

$$d(\mathbf{x}) = w_1x_1 + w_2x_2 + w_3 = 0$$

其中 x_1 、 x_2 为坐标变量， w_1 、 w_2 、 w_3 为参数方程，则将一个不知类别的模式代入 $d(\mathbf{x})$ ，有

- 若 $d(\mathbf{x}) > 0$ ，则 $\mathbf{x} \in \omega_1$
- 若 $d(\mathbf{x}) < 0$ ，则 $\mathbf{x} \in \omega_2$

此时， $d(\mathbf{x})=0$ 称为决策面/判别界面方程。

- n 维线性判别函数的一般形式

一个 n 维线性判别函数的一般形式：

$$d(\mathbf{x}) = w_1 x_1 + w_2 x_2 + \cdots + w_n x_n + w_{n+1} = \mathbf{w}_0^T \mathbf{x} + w_{n+1}$$

其中 $\mathbf{w}_0 = (w_1, w_2, \dots, w_n)^T$ 称为权向量(或参数向量), $\mathbf{x} = (x_1, x_2, \dots, x_n)^T$ 。

$d(\mathbf{x})$ 也可表示为：

$$d(\mathbf{x}) = \mathbf{w}^T \mathbf{x}$$

其中, $\mathbf{x} = (x_1, x_2, \dots, x_n, 1)^T$ 称为增广模式向量, $\mathbf{w} = (w_1, w_2, \dots, w_{n+1})^T$ 称为增广权向量。

- 两类情况：判别函数 $d(\mathbf{x})$

$$d(\mathbf{x}) = \mathbf{w}^T \mathbf{x} = \begin{cases} > 0 & \text{if } \mathbf{x} \in \omega_1 \\ \leq 0 & \text{if } \mathbf{x} \in \omega_2 \end{cases}$$

● 多类情况 1

用线性判别函数将属于 ω_i 类的模式与不属于 ω_i 类的模式分开，其判别函数为：

$$d(\mathbf{x}) = \mathbf{w}^T \mathbf{x} = \begin{cases} > 0 & \text{if } \mathbf{x} \in \omega_i \\ \leq 0 & \text{if } \mathbf{x} \notin \omega_i \end{cases}$$

$$i = 1, 2, \dots, M$$

这种情况称为 $\omega_i / \bar{\omega}_i$ 两分法，即把 M 类多类问题分成 M 个两类问题，因此共有 M 个判别函数，对应的判别函数的权向量为 $\mathbf{w}_i, i = 1, 2, \dots, M$ 。

图例：对一个三类情况，每一类模式可用一个简单的直线判别界面将它与其它类模式分开。

例如对 $\mathbf{x} \in \omega_1$ 的模式，应同时满足： $d_1(\mathbf{x}) > 0, d_2(\mathbf{x}) < 0, d_3(\mathbf{x}) < 0$

不确定区域：若对某一模式区域， $d_i(\mathbf{x}) > 0$ 的条件超过一个，或全部


$d_i(\mathbf{x}) < 0, i = 1, 2, \dots, M$ ，则分类失败，这种区域称为不确定区域(IR)。

例：设有一个三类问题，其判别式为：

$$d_1(\mathbf{x}) = -x_1 + x_2, \quad d_2(\mathbf{x}) = x_1 + x_2 - 5, \quad d_3(\mathbf{x}) = -x_2 + 1$$

则对一个模式 $\mathbf{x} = (6, 5)^T$ ，判断其属于哪一类。

将 $\mathbf{x} = (6, 5)^T$ 代入上述判别函数，得：



$$d_1(\mathbf{x}) = -1, \text{ 故 } d_1(\mathbf{x}) < 0$$

$$d_2(\mathbf{x}) = 6, \text{ 故 } d_2(\mathbf{x}) > 0$$

$$d_3(\mathbf{x}) = -4, \text{ 故 } d_3(\mathbf{x}) < 0$$

从而 $\mathbf{x} \in \omega_2$

假若 $\mathbf{x} = (3, 5)^\top$, 则

$$d_1(\mathbf{x}) = 2 > 0$$

$$d_2(\mathbf{x}) = 3 > 0$$

$$d_3(\mathbf{x}) = -2 < 0$$

分类失败。

● 多类情况 2


采用每对划分，即 ω_i / ω_j 两分法，
此时一个判别界面只能分开两种类别，
但不能把它与其余所有的界面分开。
其判别函数为：

$$d_{ij}(\mathbf{x}) = \mathbf{w}_{ij}^T \mathbf{x}$$

若 $d_{ij}(\mathbf{x}) > 0, \forall j \neq i$ ，则 $\mathbf{x} \in \omega_i$

重要性质： $d_{ij} = -d_{ji}$

图例： 对一个三类情况， $d_{12}(\mathbf{x})=0$ 仅能
分开 ω_1 和 ω_2 类，不能分开 ω_1
和 ω_3 类。



要分开 M 类模式，共需 $M(M-1)/2$ 个判别函数。

不确定区域：若所有 $d_{ij}(\mathbf{x})$ ，找不到 $\forall j \neq i, d_{ij}(\mathbf{x}) > 0$ 的情况。

例：设有一个三类问题，其判别函数为：

$$d_{12}(\mathbf{x}) = -x_1 - x_2 + 5, \quad d_{13}(\mathbf{x}) = -x_1 + 3, \quad d_{23}(\mathbf{x}) = -x_1 + x_2$$

若 $\mathbf{x} = (4, 3)^T$ ，则： $d_{12}(\mathbf{x}) = -2, d_{13}(\mathbf{x}) = -1, d_{23}(\mathbf{x}) = -1$

$$\text{有：} \begin{cases} d_{12}(\mathbf{x}) < 0 \\ d_{13}(\mathbf{x}) < 0 \end{cases}, \begin{cases} d_{21}(\mathbf{x}) = -d_{12}(\mathbf{x}) > 0 \\ d_{23}(\mathbf{x}) < 0 \end{cases}, \begin{cases} d_{31}(\mathbf{x}) = -d_{13}(\mathbf{x}) > 0 \\ d_{32}(\mathbf{x}) = -d_{23}(\mathbf{x}) > 0 \end{cases}$$

从而 $\mathbf{x} \in \omega_3$

若 $\mathbf{x} = (2.8, 2.5)^T$ ，则： $d_{12}(\mathbf{x}) = -0.3, d_{13}(\mathbf{x}) = 0.2, d_{23}(\mathbf{x}) = -0.3$

$$\text{有：} \begin{cases} d_{12}(\mathbf{x}) < 0 \\ d_{13}(\mathbf{x}) > 0 \end{cases}, \begin{cases} d_{21}(\mathbf{x}) > 0 \\ d_{23}(\mathbf{x}) < 0 \end{cases}, \begin{cases} d_{31}(\mathbf{x}) < 0 \\ d_{32}(\mathbf{x}) > 0 \end{cases}$$

分类失败。

● 多类情况 3（多类情况 2 的特例）

这是没有不确定区域的 ω_i / ω_j 两分法。假若多类情况 2 中的 d_{ij} 可分解成： $d_{ij}(\mathbf{x}) = d_i(\mathbf{x}) - d_j(\mathbf{x}) = (\mathbf{w}_i - \mathbf{w}_j)^T \mathbf{x}$ ，则 $d_{ij}(\mathbf{x}) > 0$ 相当于 $d_i(\mathbf{x}) > d_j(\mathbf{x})$ ， $\forall j \neq i$ ，这时不存在不确定区域。此时，对 M 类情况应有 M 个判别函数：


$$d_k(\mathbf{x}) = \mathbf{w}_k^T \mathbf{x}, k = 1, 2, \dots, M$$

即 $d_i(\mathbf{x}) > d_j(\mathbf{x})$ ， $\forall j \neq i$ ， $i, j = 1, 2, \dots, M$ ，

则 $\mathbf{x} \in \omega_i$ ，也可写成，若

$d_i(\mathbf{x}) = \max\{d_k(\mathbf{x}), k=1, 2, \dots, M\}$ ，则 $\mathbf{x} \in \omega_i$ 。

该分类的特点是把 M 类情况分成 $M-1$ 个两类问题。



例：设有一个三类问题的模式分类器，其判别函数为：

$$d_1(\mathbf{x}) = -x_1 + x_2, \quad d_2(\mathbf{x}) = x_1 + x_2 - 1, \quad d_3(\mathbf{x}) = -x_2$$

属于 ω_1 类的区域应满足 $d_1(\mathbf{x}) > d_2(\mathbf{x})$ 且 $d_1(\mathbf{x}) > d_3(\mathbf{x})$ ， ω_1 类的判别界面为：

$$d_{12}(\mathbf{x}) = d_1(\mathbf{x}) - d_2(\mathbf{x}) = -2x_1 + 1 = 0$$

$$d_{13}(\mathbf{x}) = d_1(\mathbf{x}) - d_3(\mathbf{x}) = -x_1 + 2x_2 = 0$$

属于 ω_2 类的区域应满足 $d_2(\mathbf{x}) > d_1(\mathbf{x})$ 且 $d_2(\mathbf{x}) > d_3(\mathbf{x})$ ， ω_2 类的判别界面为：

$$d_{21}(\mathbf{x}) = d_2(\mathbf{x}) - d_1(\mathbf{x}) = 2x_1 - 1 = 0, \quad \text{可看出 } d_{21}(\mathbf{x}) = -d_{12}(\mathbf{x})$$

$$d_{23}(\mathbf{x}) = d_2(\mathbf{x}) - d_3(\mathbf{x}) = x_1 + 2x_2 - 1 = 0$$

同理可得 ω_3 类的判别界面为：

$$d_{31}(\mathbf{x}) = -d_{13}(\mathbf{x}) = x_1 - 2x_2 = 0$$

$$d_{32}(\mathbf{x}) = -d_{23}(\mathbf{x}) = -x_1 - 2x_2 + 1 = 0$$

若有模式样本 $\mathbf{x} = (1, 1)^\top$ ，则： $d_1(\mathbf{x}) = 0$ ， $d_2(\mathbf{x}) = 1$ ， $d_3(\mathbf{x}) = -1$

从而： $d_2(\mathbf{x}) > d_1(\mathbf{x})$ 且 $d_2(\mathbf{x}) > d_3(\mathbf{x})$ ，故 $\mathbf{x} \in \omega_2$

- 广义线性判别函数的描述

一个非线性判别函数可如下表示：

$$d(\mathbf{x}) = w_1 f_1(\mathbf{x}) + w_2 f_2(\mathbf{x}) + \cdots + w_k f_k(\mathbf{x}) + w_{k+1}$$

其中 $\{f_i(\mathbf{x}), i = 1, 2, \dots, k\}$ 是模式 \mathbf{x} 的单值实函数。若定义成广义形式：

$$\mathbf{x}^* = (f_1(\mathbf{x}), f_2(\mathbf{x}), \dots, f_k(\mathbf{x}), 1)^T$$

此时有：

$$d(\mathbf{x}^*) = \mathbf{w}^T \mathbf{x}^*, \text{ 其中 } \mathbf{w} = (w_1, w_2, \dots, w_k, w_{k+1})^T$$

该式表明，非线性判别函数已被变换成广义线性，因此只讨论线性判别函数不会失去一般性意义。

- 线性判别函数

取 $f_i(\mathbf{x})$ 为一次函数，例如 x_i ，则变换后的模式 $\mathbf{x}^* = \mathbf{x}$ ， \mathbf{x}^* 的维数为 \mathbf{x} 的维数是 n ，此时广义线性化后的判别式仍为：

$$d(\mathbf{x}) = \mathbf{w}^T \mathbf{x} + w_{n+1}$$

- $f_i(\mathbf{x})$ 选用二次多项式函数

1. \mathbf{x} 是二维的情况，即 $\mathbf{x} = (x_1 \ x_2)^T$ 。若原判别函数为：

$$d(\mathbf{x}) = w_{11}x_1^2 + w_{12}x_1x_2 + w_{22}x_2^2 + w_1x_1 + w_2x_2 + w_3$$

要线性化为 $d(\mathbf{x}^*) = \mathbf{w}^T \mathbf{x}^*$ ，须定义：

$$\mathbf{x}^* = (x_1^2 \ x_1x_2 \ x_2^2 \ x_1 \ x_2 \ 1)^T$$

$$\mathbf{w} = (w_{11} \ w_{12} \ w_{22} \ w_1 \ w_2 \ w_3)^T$$

此时，只要把模式空间 \mathbf{x}^* 中的分量定义成 \mathbf{x} 的单值实函数， \mathbf{x}^* 即变成线性可分。此时 \mathbf{x}^* 的维数（这里为 6）大于 \mathbf{x} 的维数（这里为 2）。

2. \mathbf{x} 是 n 维的情况，此时原判别函数设为：

$$d(\mathbf{x}) = \sum_{j=1}^n w_{jj}x_j^2 + \sum_{j=1}^{n-1} \sum_{k=j+1}^n w_{jk}x_jx_k + \sum_{j=1}^n w_jx_j + w_{n+1}$$

式中各项的组成应包含 \mathbf{x} 的各个分量的二次项、一次项和常数项，其中平方项 n 个，二次项 $n(n-1)/2$ 个，一次项 n 个，常数项一个，其总项数为：

$$n + n(n-1)/2 + n + 1 = (n+1)(n+2)/2 > n$$

显然，对于 $d(\mathbf{x}^*) = \mathbf{w}^T \mathbf{x}^*$ ， \mathbf{x}^* 的维数大于 \mathbf{x} 的维数， \mathbf{w} 分量的数目也与 \mathbf{x}^* 的维数相应。 \mathbf{x}^* 的各分量的一般化形式为：

$$f_i(\mathbf{x}) = x_{p_1}^s x_{p_2}^t, p_1, p_2 = 1, 2, \dots, n, \quad s, t = 0, 1$$

- $f_i(\mathbf{x})$ 为 r 次多项式函数, \mathbf{x} 为 n 维模式, 则有

$$f_i(\mathbf{x}) = x_{p_1}^{s_1} x_{p_2}^{s_2} \cdots x_{p_r}^{s_r}, p_1, p_2, \cdots, p_r = 1, 2, \cdots, n, s_1, s_2, \cdots, s_r = 0, 1$$

此时, 判别函数 $d(\mathbf{x})$ 可用以下递推关系给出:

$$\text{常数项: } d^{(0)}(\mathbf{x}) = w_{n+1}$$

$$\text{一次项: } d^{(1)}(\mathbf{x}) = \sum_{p_1=1}^n w_{p_1} x_{p_1} + d^{(0)}(\mathbf{x})$$

$$\text{二次项: } d^{(2)}(\mathbf{x}) = \sum_{p_1=1}^n \sum_{p_2=p_1}^n w_{p_1 p_2} x_{p_1} x_{p_2} + d^{(1)}(\mathbf{x})$$

$$\text{r 次项: } d^{(r)}(\mathbf{x}) = \sum_{p_1=1}^n \sum_{p_2=p_1}^n \cdots \sum_{p_r=p_{r-1}}^n w_{p_1 p_2 \cdots p_r} x_{p_1} x_{p_2} \cdots x_{p_r} + d^{(r-1)}(\mathbf{x})$$

- $d(\mathbf{x})$ 总项数的讨论: 对于 n 维 \mathbf{x} 向量, 若用 r 次多项式, $d(\mathbf{x})$ 的权

$$\text{系数的总项数为: } N_w = C_{n+r}^r = \frac{(n+r)!}{r!n!}$$

$$\text{当 } r=2 \text{ 时: } N_w = C_{n+2}^2 = \frac{(n+2)!}{2!n!} = \frac{(n+2)(n+1)}{2}$$

$$\text{当 } r=3 \text{ 时: } N_w = C_{n+3}^3 = \frac{(n+3)!}{3!n!} = \frac{(n+3)(n+2)(n+1)}{6}$$

- 用 $d^{(r)}(x)$ 写出 $r=2$ 和 $n=2$ 时的判别函数


常数项: $d^{(0)}(\mathbf{x}) = w_{n+1} = w_3$

一次项: $d^{(1)}(\mathbf{x}) = \sum_{p_1=1}^n w_{p_1} x_{p_1} + d^{(0)}(\mathbf{x}) = w_1 x_1 + w_2 x_2 + w_3$

二次项:
$$d^{(2)}(\mathbf{x}) = \sum_{p_1=1}^n \sum_{p_2=p_1}^n w_{p_1 p_2} x_{p_1} x_{p_2} + d^{(1)}(\mathbf{x})$$

$$= w_{11} x_1^2 + w_{12} x_1 x_2 + w_{22} x_2^2 + w_1 x_1 + w_2 x_2 + w_3$$

- 广义线性判别实例



如图所示，设有一维样本空间 X ，所希望的分类是：

若 $x \leq b$ 或 $x \geq a$, $x \in \omega_1$; 若 $b < x < a$, $x \in \omega_2$

显然没有一个线性判别函数能在一维空间中解决上述问题。

要在一维空间中分类，只有定义判别函数

$$d(x) = (x-a)(x-b) = x^2 - (a+b)x + ab$$

将此分类问题转化到二维空间，令

$$x_1 = f_1(x) = x^2, x_2 = f_2(x) = x$$

则可以定义线性判别函数

$$d(\mathbf{x}) = x_1 - (a+b)x_2 + ab = \mathbf{w}^T \mathbf{x}$$

此时


$$\mathbf{x} = (x_1 \ x_2 \ 1)^T, \mathbf{w} = (1 \ -(a+b) \ ab)^T$$

- 最小距离分类

设 μ_1 和 μ_2 为两个模式类 ω_1 和 ω_2 的聚类中心，定义决策规则：

$$\|x - \mu_1\|^2 - \|x - \mu_2\|^2 \begin{cases} < 0 & x \in \omega_1 \\ > 0 & x \in \omega_2 \end{cases}$$

这时的决策面是两类期望连线的垂直平分面，这样的分类器称为最小距离分类器。



● 分类描述

设有判别函数： $d(\mathbf{x})=\mathbf{w}^T\mathbf{x}$ ，其中 $\mathbf{x}=(x_1\ x_2\ \dots\ x_n\ 1)^T$ ， $\mathbf{w}=(w_1\ w_2\ \dots\ w_n\ w_{n+1})^T$

判别界面为： $\mathbf{w}^T\mathbf{x}=0$

对两类问题， ω_1 类有模式 $\{\mathbf{x}_1\ \mathbf{x}_2\}$ ， ω_2 类有模式 $\{\mathbf{x}_3\ \mathbf{x}_4\}$ ，则应满足如下条件：

$$\left. \begin{array}{ll} \mathbf{w}^T\mathbf{x}_1 > 0 & \mathbf{w}^T\mathbf{x}_2 > 0 \\ \mathbf{w}^T\mathbf{x}_3 < 0 & \mathbf{w}^T\mathbf{x}_4 < 0 \end{array} \right\}$$

若将属于 ω_2 类的模式都乘以(-1)，则上式可写成：

$$\left. \begin{array}{ll} \mathbf{w}^T\mathbf{x}_1 > 0 & \mathbf{w}^T\mathbf{x}_2 > 0 \\ \mathbf{w}^T(-\mathbf{x}_3) > 0 & \mathbf{w}^T(-\mathbf{x}_4) > 0 \end{array} \right\}$$

因此，若权向量能满足上述四个条件，则 $\mathbf{w}^T\mathbf{x}=0$ 为所给模式集的判别界面。

● Fisher 准则函数中的基本参量

1. 在 d 维 \mathbf{X} 空间

(1) 各类样本的均值向量 \mathbf{m}_i

$$\mathbf{m}_i = \frac{1}{N_i} \sum_{\mathbf{x} \in \Gamma_i} \mathbf{x}, i=1,2,$$

(2) 样本类内离散度矩阵 \mathbf{S}_i 和总样本类内离散度矩阵 \mathbf{S}_w

$$\mathbf{S}_i = \sum_{\mathbf{x} \in \Gamma_i} (\mathbf{x} - \mathbf{m}_i)(\mathbf{x} - \mathbf{m}_i)^T, i=1,2,$$
$$\mathbf{S}_w = \mathbf{S}_1 + \mathbf{S}_2$$

其中 \mathbf{S}_w 是对称半正定矩阵, 而且当 $N > d$ 时通常是非奇异的。

(3) 样本类间离散度矩阵 \mathbf{S}_b

$$\mathbf{S}_b = (\mathbf{m}_1 - \mathbf{m}_2)(\mathbf{m}_1 - \mathbf{m}_2)^T$$

\mathbf{S}_b 是对称半正定矩阵。

2. 在一维 Y 空间

(1) 各类样本的均值 \tilde{m}_i

$$\tilde{m}_i = \frac{1}{N_i} \sum_{y \in \Gamma'_i} y, i=1,2$$

(2) 样本类内离散度 \tilde{S}_i^2 和总样本类内离散度 \tilde{S}_w

$$\tilde{S}_i^2 = \sum_{y \in \Gamma'_i} (y - \tilde{m}_i)^2, i=1,2$$
$$\tilde{S}_w = \tilde{S}_1^2 + \tilde{S}_2^2$$

● Fisher 准则函数

Fisher 准则函数定义为：

$$J_F(\mathbf{w}) = \frac{(\tilde{m}_1 - \tilde{m}_2)^2}{\tilde{S}_1^2 + \tilde{S}_2^2}$$

其中， $(\tilde{m}_1 - \tilde{m}_2)$ 是两类均值之差， \tilde{S}_i^2 是样本类内离散度。显然，应该使 $J_F(\mathbf{w})$ 的分子尽可能大而分母尽可能小，即应寻找使 $J_F(\mathbf{w})$ 尽可能大的 \mathbf{w} 作为投影方向。但上式中并不显含 \mathbf{w} ，因此须设法将 $J_F(\mathbf{w})$ 变成 \mathbf{w} 的显函数。

由各类样本的均值可推出：

$$\tilde{m}_i = \frac{1}{N_i} \sum_{y \in \Gamma_i} y = \frac{1}{N_i} \sum_{x \in \Gamma_i} \mathbf{w}^T \mathbf{x} = \mathbf{w}^T \frac{1}{N_i} \left(\sum_{x \in \Gamma_i} \mathbf{x} \right) = \mathbf{w}^T \mathbf{m}_i$$

这样，Fisher 准则函数 $J_F(\mathbf{w})$ 的分子可写成：

$$\begin{aligned} (\tilde{m}_1 - \tilde{m}_2)^2 &= (\mathbf{w}^T \mathbf{m}_1 - \mathbf{w}^T \mathbf{m}_2)^2 \\ &= (\mathbf{w}^T \mathbf{m}_1 - \mathbf{w}^T \mathbf{m}_2) (\mathbf{w}^T \mathbf{m}_1 - \mathbf{w}^T \mathbf{m}_2)^T \\ &= (\mathbf{w}^T \mathbf{m}_1 - \mathbf{w}^T \mathbf{m}_2) (\mathbf{m}_1^T \mathbf{w} - \mathbf{m}_2^T \mathbf{w}) \\ &= \mathbf{w}^T (\mathbf{m}_1 - \mathbf{m}_2) (\mathbf{m}_1 - \mathbf{m}_2)^T \mathbf{w} = \mathbf{w}^T \mathbf{S}_b \mathbf{w} \end{aligned}$$

现在再来考察 $J_F(\mathbf{w})$ 的分母与 \mathbf{w} 的关系：

$$\begin{aligned} \tilde{S}_i^2 &= \sum_{y \in \Gamma_i} (y - \tilde{m}_i)^2 = \sum_{x \in \Gamma_i} (\mathbf{w}^T \mathbf{x} - \mathbf{w}^T \mathbf{m}_i)^2 \\ &= \mathbf{w}^T \left[\sum_{x \in \Gamma_i} (\mathbf{x} - \mathbf{m}_i)(\mathbf{x} - \mathbf{m}_i)^T \right] \mathbf{w} \\ &= \mathbf{w}^T \left[\sum_{x \in \Gamma_i} (\mathbf{x} - \mathbf{m}_i)(\mathbf{x} - \mathbf{m}_i)^T \right] \mathbf{w} \\ &= \mathbf{w}^T \mathbf{S}_i \mathbf{w} \end{aligned}$$

因此，

$$\tilde{S}_1^2 + \tilde{S}_2^2 = \mathbf{w}^T (\mathbf{S}_1 + \mathbf{S}_2) \mathbf{w} = \mathbf{w}^T \mathbf{S}_w \mathbf{w}$$

将上述各式代入 $J_F(\mathbf{w})$ ，可得：

$$J_F(\mathbf{w}) = \frac{\mathbf{w}^T \mathbf{S}_b \mathbf{w}}{\mathbf{w}^T \mathbf{S}_w \mathbf{w}}$$

其中 \mathbf{S}_b 为样本类间离散度矩阵， \mathbf{S}_w 为总样本类内离散度矩阵。

● 最佳变换向量 \mathbf{w}^* 的求取

为求使 $J_F(\mathbf{w}) = \frac{\mathbf{w}^T \mathbf{S}_b \mathbf{w}}{\mathbf{w}^T \mathbf{S}_w \mathbf{w}}$ 取极大值时的 \mathbf{w}^* ，可以采用 [Lagrange 乘数](#)

[法](#)求解。令分母等于非零常数，即：

$$\mathbf{w}^T \mathbf{S}_w \mathbf{w} = c \neq 0$$

定义 Lagrange 函数为：

$$L(\mathbf{w}, \lambda) = \mathbf{w}^T \mathbf{S}_b \mathbf{w} - \lambda(\mathbf{w}^T \mathbf{S}_w \mathbf{w} - c)$$

其中 λ 为 Lagrange 乘子。将上式对 \mathbf{w} 求偏导数，可得：

$$\frac{\partial L(\mathbf{w}, \lambda)}{\partial \mathbf{w}} = \mathbf{S}_b \mathbf{w} + \mathbf{S}_b^T \mathbf{w} - \lambda(\mathbf{S}_w \mathbf{w} + \mathbf{S}_w^T \mathbf{w}) = 2\mathbf{S}_b \mathbf{w} - \lambda 2\mathbf{S}_w \mathbf{w}$$

令偏导数为零，有：

$$\mathbf{S}_b \mathbf{w}^* - \lambda \mathbf{S}_w \mathbf{w}^* = 0$$

y 是标量， $\mathbf{x} = [x_1 \ x_2 \ \dots \ x_d]^T$ 是 d 维列向量，则 $\frac{\partial y}{\partial \mathbf{x}} = \left[\frac{\partial y}{\partial x_1} \ \frac{\partial y}{\partial x_2} \ \dots \ \frac{\partial y}{\partial x_d} \right]^T$

常用求导公式：

注：

$$\frac{\partial \mathbf{A} \mathbf{x}}{\partial \mathbf{x}} = \mathbf{A}^T$$

$$\frac{\partial \mathbf{x}^T \mathbf{x}}{\partial \mathbf{x}} = 2\mathbf{x}$$

$$\frac{\partial \mathbf{x}^T \mathbf{A} \mathbf{x}}{\partial \mathbf{x}} = \mathbf{A} \mathbf{x} + \mathbf{A}^T \mathbf{x}$$

即

$$\mathbf{S}_b \mathbf{w}^* = \lambda \mathbf{S}_w \mathbf{w}^*$$

其中 \mathbf{w}^* 就是 $J_F(\mathbf{w})$ 的极值解。因为 \mathbf{S}_w 非奇异，将上式两边左乘 \mathbf{S}_w^{-1} ，

可得：

$$\mathbf{S}_w^{-1} \mathbf{S}_b \mathbf{w}^* = \lambda \mathbf{w}^*$$

上式为求一般矩阵 $S_w^{-1}S_b$ 的特征值问题。利用 $S_b = (m_1 - m_2)(m_1 - m_2)^T$ 的定义，将上式左边的 $S_b w^*$ 写成：

$$S_b w^* = (m_1 - m_2)(m_1 - m_2)^T w^* = (m_1 - m_2)R$$

其中 $R = (m_1 - m_2)^T w^*$ 为一标量，所以 $S_b w^*$ 总是在向量 $(m_1 - m_2)$ 的方向上。因此 λw^* 可写成：

$$\lambda w^* = S_w^{-1}S_b w^* = S_w^{-1}(m_1 - m_2)R$$

从而可得：

$$w^* = \frac{R}{\lambda} S_w^{-1}(m_1 - m_2)$$

由于我们的目的是寻找最佳的投影方向， w^* 的比例因子对此并无影响，因此可忽略比例因子 $\frac{R}{\lambda}$ ，有：

$$w^* = S_w^{-1}(m_1 - m_2)$$

● 感知器的训练算法

已知两个训练模式集分别属于 ω_1 类和 ω_2 类，权向量的初始值为 $\mathbf{w}(1)$ ，可任意取值。若 $\mathbf{x}^k \in \omega_1, \mathbf{w}^T(k)\mathbf{x}^k > 0$ ，若 $\mathbf{x}^k \in \omega_2, \mathbf{w}^T(k)\mathbf{x}^k \leq 0$ ，则在用全部训练模式集进行迭代训练时，第 k 次的训练步骤为：

- 若 $\mathbf{x}^k \in \omega_1$ 且 $\mathbf{w}^T(k)\mathbf{x}^k \leq 0$ ，则分类器对第 k 个模式 \mathbf{x}^k 做了错误分类，此时应校正权向量，使得 $\mathbf{w}(k+1) = \mathbf{w}(k) + C\mathbf{x}^k$ ，其中 C 为一个校正增量。
- 若 $\mathbf{x}^k \in \omega_2$ 且 $\mathbf{w}^T(k)\mathbf{x}^k > 0$ ，同样分类器分类错误，则权向量应校正如下： $\mathbf{w}(k+1) = \mathbf{w}(k) - C\mathbf{x}^k$
- 若以上情况不符合，则表明该模式样本在第 k 次中分类正确，因此权向量不变，即： $\mathbf{w}(k+1) = \mathbf{w}(k)$

若对 $\mathbf{x}^k \in \omega_2$ 的模式样本乘以(-1)，则有：

$$\mathbf{w}^T(k)\mathbf{x}^k \leq 0 \text{ 时, } \mathbf{w}(k+1) = \mathbf{w}(k) + C\mathbf{x}^k$$

此时，感知器算法可统一写成：

$$\mathbf{w}(k+1) = \begin{cases} \mathbf{w}(k) & , \text{ if } \mathbf{w}^T(k)\mathbf{x}^k > 0 \\ \mathbf{w}(k) + C\mathbf{x}^k & \text{ if } \mathbf{w}^T(k)\mathbf{x}^k \leq 0 \end{cases}$$

- 感知器的训练算法实例

将属于 ω_2 的训练样本乘以 (-1) ，并写成增广向量的形式。

$$\mathbf{x}^1=(0\ 0\ 1)^T, \mathbf{x}^2=(0\ 1\ 1)^T, \mathbf{x}^3=(-1\ 0\ -1)^T, \mathbf{x}^4=(-1\ -1\ -1)^T$$

第一轮迭代：取 $C=1$ ， $\mathbf{w}(1)=(0\ 0\ 0)^T$

因 $\mathbf{w}^T(1)\mathbf{x}^1=(0\ 0\ 0)(0\ 0\ 1)^T=0 \not> 0$ ，故 $\mathbf{w}(2)=\mathbf{w}(1)+\mathbf{x}^1=(0\ 0\ 1)^T$

因 $\mathbf{w}^T(2)\mathbf{x}^2=(0\ 0\ 1)(0\ 1\ 1)^T=1>0$ ，故 $\mathbf{w}(3)=\mathbf{w}(2)=(0\ 0\ 1)^T$

因 $\mathbf{w}^T(3)\mathbf{x}^3=(0\ 0\ 1)(-1\ 0\ -1)^T=-1 \not> 0$ ，故 $\mathbf{w}(4)=\mathbf{w}(3)+\mathbf{x}^3=(-1\ 0\ 0)^T$

因 $\mathbf{w}^T(4)\mathbf{x}^4=(-1\ 0\ 0)(-1\ -1\ -1)^T=1>0$ ，故 $\mathbf{w}(5)=\mathbf{w}(4)=(-1\ 0\ 0)^T$

这里，第 1 步和第 3 步为错误分类，应“罚”。

因为只有对全部模式都能正确判别的权向量才是正确的解，因此需进行第二轮迭代。

第二轮迭代：

因 $\mathbf{w}^T(5)\mathbf{x}_{\textcircled{1}}=(-1\ 0\ 0)(0\ 0\ 1)^T=0 \not> 0$ ，故 $\mathbf{w}(6)=\mathbf{w}(5)+\mathbf{x}_{\textcircled{1}}=(-1\ 0\ 1)^T$

因 $\mathbf{w}^T(6)\mathbf{x}_{\textcircled{2}}=(-1\ 0\ 1)(0\ 1\ 1)^T=1>0$ ，故 $\mathbf{w}(7)=\mathbf{w}(6)=(-1\ 0\ 1)^T$

因 $\mathbf{w}^T(7)\mathbf{x}_{\textcircled{3}}=(-1\ 0\ 1)(-1\ 0\ -1)^T=0 \not> 0$ ，故 $\mathbf{w}(8)=\mathbf{w}(7)+\mathbf{x}_{\textcircled{3}}=(-2\ 0\ 0)^T$

因 $\mathbf{w}^T(8)\mathbf{x}_{\textcircled{4}}=(-2\ 0\ 0)(-1\ -1\ -1)^T=2>0$ ，故 $\mathbf{w}(9)=\mathbf{w}(8)=(-2\ 0\ 0)^T$

需进行第三轮迭代。

第三轮迭代：

因 $\mathbf{w}^T(9)\mathbf{x}^1=(-2\ 0\ 0)(0\ 0\ 1)^T=0 \not> 0$ ，故 $\mathbf{w}(10)=\mathbf{w}(9)+\mathbf{x}^1=(-2\ 0\ 1)^T$

因 $\mathbf{w}^T(10) \mathbf{x}^2 = (-2 \ 0 \ 1)(0 \ 1 \ 1)^T = 1 > 0$, 故 $\mathbf{w}(11) = \mathbf{w}(10) = (-2 \ 0 \ 1)^T$

因 $\mathbf{w}^T(11) \mathbf{x}^3 = (-2 \ 0 \ 1)(-1 \ 0 \ -1)^T = 1 > 0$, 故 $\mathbf{w}(12) = \mathbf{w}(11) = (-2 \ 0 \ 1)^T$

因 $\mathbf{w}^T(12) \mathbf{x}^4 = (-2 \ 0 \ 1)(-1 \ -1 \ -1)^T = 1 > 0$, 故 $\mathbf{w}(13) = \mathbf{w}(12) = (-2 \ 0 \ 1)^T$

需进行第四轮迭代。

第四轮迭代:

因 $\mathbf{w}^T(13) \mathbf{x}^1 = 1 > 0$, 故 $\mathbf{w}(14) = \mathbf{w}(13) = (-2 \ 0 \ 1)^T$

因 $\mathbf{w}^T(14) \mathbf{x}^2 = 1 > 0$, 故 $\mathbf{w}(15) = \mathbf{w}(10) = (-2 \ 0 \ 1)^T$

因 $\mathbf{w}^T(15) \mathbf{x}^3 = 1 > 0$, 故 $\mathbf{w}(16) = \mathbf{w}(11) = (-2 \ 0 \ 1)^T$

因 $\mathbf{w}^T(16) \mathbf{x}^4 = 1 > 0$, 故 $\mathbf{w}(17) = \mathbf{w}(12) = (-2 \ 0 \ 1)^T$

该轮的迭代全部正确, 因此解向量 $\mathbf{w} = (-2 \ 0 \ 1)^T$, 相应的判别函数为:

$$d(\mathbf{x}) = -2x_1 + 1$$

- 感知器算法判别函数的推导

多类情况 3: 对 M 类模式存在 M 个判别函数 $\{d_i, i = 1, 2, \dots, M\}$, 若 $\mathbf{x}_k \in \omega_i$, 则 $d_i > d_j, \forall j \neq i$ 。

设有 M 种模式类别 $\omega_1, \omega_2, \dots, \omega_M$, 若在训练过程的第 k 次迭代时, 一个属于 ω_i 类的模式样本 \mathbf{x} 送入分类器, 则应先计算出 M 个判别函数:

$$d_j(k) = \mathbf{w}_j(k)\mathbf{x}, j = 1, 2, \dots, M$$

若 $d_i(k) > d_j(k), j = 1, 2, \dots, M, \forall j \neq i$ 的条件成立, 则权向量不变, 即

$$\mathbf{w}_j(k+1) = \mathbf{w}_j(k), j = 1, 2, \dots, M$$

若其中第 l 个权向量使得 $d_i(k) \leq d_l(k)$, 则相应的权向量应做调整,

即

$$\mathbf{w}_i(k+1) = \mathbf{w}_i(k) + C\mathbf{x}$$

$$\mathbf{w}_l(k+1) = \mathbf{w}_l(k) - C\mathbf{x}$$

$$\mathbf{w}_j(k+1) = \mathbf{w}_j(k), j = 1, 2, \dots, M, j \neq i, j \neq l$$

其中 C 是一个正常数。权向量的初始值 $\mathbf{w}_i(l), i = 1, 2, \dots, M$ 可视情况任意选择。

- 感知器算法判别函数的推导实例

给出三类模式的训练样本：

$$\omega_1: \{(0\ 0)^T\}, \omega_2: \{(1\ 1)^T\}, \omega_3: \{(-1\ 1)^T\}$$

将模式样本写成增广形式：

$$\mathbf{x}^1 = (0\ 0\ 1)^T, \mathbf{x}^2 = (1\ 1\ 1)^T, \mathbf{x}^3 = (-1\ 1\ 1)^T$$

取初始值 $\mathbf{w}_1(1) = \mathbf{w}_2(1) = \mathbf{w}_3(1) = (0\ 0\ 0)^T$, $C=1$ 。

第一轮迭代 ($k=1$): 以 $\mathbf{x}^1 = (0\ 0\ 1)^T$ 作为训练样本

$$d_1(1) = \mathbf{w}_1^T(1) \mathbf{x}^1 = (0\ 0\ 0)(0\ 0\ 1)^T = 0$$

$$d_2(1) = \mathbf{w}_2^T(1) \mathbf{x}^1 = (0\ 0\ 0)(0\ 0\ 1)^T = 0$$

$$d_3(1) = \mathbf{w}_3^T(1) \mathbf{x}^1 = (0\ 0\ 0)(0\ 0\ 1)^T = 0$$

因 $d_1(1) \not> d_2(1)$, $d_1(1) \not> d_3(1)$, 故

$$\mathbf{w}_1(2) = \mathbf{w}_1(1) + \mathbf{x}^1 = (0\ 0\ 1)^T$$

$$\mathbf{w}_2(2) = \mathbf{w}_2(1) - \mathbf{x}^1 = (0\ 0\ -1)^T$$

$$\mathbf{w}_3(2) = \mathbf{w}_3(1) - \mathbf{x}^1 = (0\ 0\ -1)^T$$

第二轮迭代 ($k=2$): 以 $\mathbf{x}^2 = (1\ 1\ 1)^T$ 作为训练样本

$$d_1(2) = \mathbf{w}_1^T(2) \mathbf{x}^2 = (0\ 0\ 1)(1\ 1\ 1)^T = 1$$

$$d_2(2) = \mathbf{w}_2^T(2) \mathbf{x}^2 = (0\ 0\ -1)(1\ 1\ 1)^T = -1$$

$$d_3(2) = \mathbf{w}_3^T(2) \mathbf{x}^2 = (0\ 0\ -1)(1\ 1\ 1)^T = -1$$

因 $d_2(2) \not> d_1(2)$, $d_3(2) \not> d_1(2)$, 故

$$\mathbf{w}_1(3) = \mathbf{w}_1(2) - \mathbf{x}^2 = (-1\ -1\ 0)^T$$

$$\mathbf{w}_2(3)=\mathbf{w}_2(2)+\mathbf{x}^2=(1 \ 1 \ 0)^T$$

$$\mathbf{w}_3(3)=\mathbf{w}_3(2)-\mathbf{x}^2=(-1 \ -1 \ -2)^T$$

第三轮迭代 (k=3): 以 $\mathbf{x}^3=(-1 \ 1 \ 1)^T$ 作为训练样本

$$d_1(3)=\mathbf{w}_1^T(3)\mathbf{x}^3=(-1 \ -1 \ 0)(-1 \ 1 \ 1)^T=0$$

$$d_2(3)=\mathbf{w}_2^T(3)\mathbf{x}^3=(1 \ 1 \ 0)(-1 \ 1 \ 1)^T=0$$

$$d_3(3)=\mathbf{w}_3^T(3)\mathbf{x}^3=(-1 \ -1 \ -2)(-1 \ 1 \ 1)^T=-2$$

因 $d_3(3) \not\geq d_1(3)$, $d_3(3) \not\geq d_2(3)$, 故

$$\mathbf{w}_1(4)=\mathbf{w}_1(3)-\mathbf{x}^3=(0 \ -2 \ -1)^T$$

$$\mathbf{w}_2(4)=\mathbf{w}_2(3)-\mathbf{x}^3=(2 \ 0 \ -1)^T$$

$$\mathbf{w}_3(4)=\mathbf{w}_3(3)+\mathbf{x}^3=(-2 \ 0 \ -1)^T$$

第四轮迭代 (k=4): 以 $\mathbf{x}^1=(0 \ 0 \ 1)^T$ 作为训练样本

$$d_1(4)=\mathbf{w}_1^T(4)\mathbf{x}^1=(0 \ -2 \ -1)(0 \ 0 \ 1)^T=-1$$

$$d_2(4)=\mathbf{w}_2^T(4)\mathbf{x}^1=(2 \ 0 \ -1)(0 \ 0 \ 1)^T=-1$$

$$d_3(4)=\mathbf{w}_3^T(4)\mathbf{x}^1=(-2 \ 0 \ -1)(0 \ 0 \ 1)^T=-1$$

因 $d_1(4) \not\geq d_2(4)$, $d_1(4) \not\geq d_3(4)$, 故

$$\mathbf{w}_1(5)=\mathbf{w}_1(4)+\mathbf{x}^1=(0 \ -2 \ 0)^T$$

$$\mathbf{w}_2(5)=\mathbf{w}_2(4)-\mathbf{x}^1=(2 \ 0 \ -2)^T$$

$$\mathbf{w}_3(5)=\mathbf{w}_3(4)-\mathbf{x}^1=(-2 \ 0 \ -2)^T$$

第五轮迭代 (k=5): 以 $\mathbf{x}^2=(1 \ 1 \ 1)^T$ 作为训练样本

$$d_1(5)=\mathbf{w}_1^T(5)\mathbf{x}^2=(0 \ -2 \ 0)(1 \ 1 \ 1)^T=-2$$

$$d_2(5)=\mathbf{w}_2^T(5)\mathbf{x}^2=(2 \ 0 \ -2)(1 \ 1 \ 1)^T=0$$

$$d_3(5)=\mathbf{w}_3^T(5)\mathbf{x}^2=(-2 \ 0 \ -2)(1 \ 1 \ 1)^T=-4$$

因 $d_2(5)>d_1(5)$, $d_2(5)>d_3(5)$, 故

$$\mathbf{w}_1(6)=\mathbf{w}_1(5)$$

$$\mathbf{w}_2(6)=\mathbf{w}_2(5)$$

$$\mathbf{w}_3(6)=\mathbf{w}_3(5)$$

第六轮迭代 (k=6): 以 $\mathbf{x}^3=(-1 \ 1 \ 1)^T$ 作为训练样本

$$d_1(6)=\mathbf{w}_1^T(6)\mathbf{x}^3=(0 \ -2 \ 0)(-1 \ 1 \ 1)^T=-2$$

$$d_2(6)=\mathbf{w}_2^T(6)\mathbf{x}^3=(2 \ 0 \ -2)(-1 \ 1 \ 1)^T=-4$$

$$d_3(6)=\mathbf{w}_3^T(6)\mathbf{x}^3=(-2 \ 0 \ -2)(-1 \ 1 \ 1)^T=0$$

因 $d_3(6)>d_1(6)$, $d_3(6)>d_2(6)$, 故

$$\mathbf{w}_1(7)=\mathbf{w}_1(6)$$

$$\mathbf{w}_2(7)=\mathbf{w}_2(6)$$

$$\mathbf{w}_3(7)=\mathbf{w}_3(6)$$

第七轮迭代 (k=7): 以 $\mathbf{x}^1=(0 \ 0 \ 1)^T$ 作为训练样本

$$d_1(7)=\mathbf{w}_1^T(7)\mathbf{x}^1=(0 \ -2 \ 0)(0 \ 0 \ 1)^T=0$$

$$d_2(7)=\mathbf{w}_2^T(7)\mathbf{x}^1=(2 \ 0 \ -2)(0 \ 0 \ 1)^T=-2$$

$$d_3(7)=\mathbf{w}_3^T(7)\mathbf{x}^1=(-2 \ 0 \ -2)(0 \ 0 \ 1)^T=-2$$

因 $d_1(7)>d_2(7)$, $d_1(7)>d_3(7)$, 分类结果正确, 故权向量不变。

由于第五、六、七次迭代中 \mathbf{x}^1 、 \mathbf{x}^2 、 \mathbf{x}^3 均已正确分类，所以权向量的解为：

$$\mathbf{w}_1 = (0 \ -2 \ 0)^T$$

$$\mathbf{w}_2 = (2 \ 0 \ -2)^T$$

$$\mathbf{w}_3 = (-2 \ 0 \ -2)^T$$

三个判别函数：

$$d_1(\mathbf{x}) = -2x_2$$

$$d_2(\mathbf{x}) = 2x_1 - 2$$

$$d_3(\mathbf{x}) = -2x_1 - 2$$

- 梯度法定义

设函数 $f(\mathbf{y})$ 是向量 $\mathbf{y} = (y_1, y_2, \dots, y_n)^T$ 的函数, 则 $f(\mathbf{y})$ 的梯度定义为:

$$\nabla f(\mathbf{y}) = \frac{d}{d\mathbf{y}} f(\mathbf{y}) = \left(\frac{\partial f}{\partial y_1} \quad \frac{\partial f}{\partial y_2} \quad \dots \quad \frac{\partial f}{\partial y_n} \right)^T$$

- 从 $\mathbf{w}(k)$ 导出 $\mathbf{w}(k+1)$ 的一般关系式

$$\mathbf{w}(k+1) = \mathbf{w}(k) - C \left\{ \frac{\partial J(\mathbf{w}, \mathbf{x})}{\partial \mathbf{w}} \right\}_{\mathbf{w}=\mathbf{w}(k)} = \mathbf{w}(k) - C \cdot \nabla J$$

C 是一个正的比例因子 (步长)

- 梯度法实例

选准则函数 $J(\mathbf{w}, \mathbf{x}) = |\mathbf{w}^T \mathbf{x}| - \mathbf{w}^T \mathbf{x}$ ，考虑一维模式的情况。

设训练样本 \mathbf{x} 为 1。

当错误分类时， $\mathbf{w}^T \mathbf{x} < 0$ ， J 为正值， $\nabla J = -2$ ，则 $\mathbf{w}(k+1) = \mathbf{w}(k) + 2C$ ，对权向量进行校正。

当正确分类时， $\mathbf{w}^T \mathbf{x} > 0$ ， $J=0$ ， $\nabla J=0$ ，则 $\mathbf{w}(k+1) = \mathbf{w}(k)$ ，权向量不变。

- 固定增量的逐次调整算法

设取准则函数为：

$$J(\mathbf{w}, \mathbf{x}) = \frac{|\mathbf{w}^T \mathbf{x}| - \mathbf{w}^T \mathbf{x}}{2}$$

则 J 对 \mathbf{w} 的微分式：

$$\frac{\partial J}{\partial \mathbf{w}} = \frac{1}{2} [\mathbf{x} \cdot \text{sign}(\mathbf{w}^T \mathbf{x}) - \mathbf{x}]$$

定义：

$$\text{sign}(\mathbf{w}^T \mathbf{x}) = \begin{cases} +1 & \text{if } \mathbf{w}^T \mathbf{x} > 0 \\ -1 & \text{if } \mathbf{w}^T \mathbf{x} \leq 0 \end{cases}$$

则由梯度法中 $\mathbf{w}(k+1)$ 和 $\mathbf{w}(k)$ 的关系有：

$$\mathbf{w}(k+1) = \mathbf{w}(k) + \frac{C}{2} [\mathbf{x}^k - \mathbf{x}^k \cdot \text{sign}(\mathbf{w}^T(k) \mathbf{x}^k)]$$

其中 \mathbf{x}^k 是训练模式样本， k 是指第 k 次迭代。

$$\mathbf{w}(k+1) = \mathbf{w}(k) + C \cdot \begin{cases} 0 & \text{if } \mathbf{w}^T \mathbf{x}^k > 0 \\ \mathbf{x}^k & \text{if } \mathbf{w}^T \mathbf{x}^k \leq 0 \end{cases}$$

可以看出，当 $\mathbf{w}^T \mathbf{x}^k > 0$ 时，则 $\mathbf{w}(k+1) = \mathbf{w}(k)$ ，此时不对权向量进行修正；当 $\mathbf{w}^T \mathbf{x}^k \leq 0$ 时，则 $\mathbf{w}(k+1) = \mathbf{w}(k) + C\mathbf{x}^k$ ，需对权向量进行校正，初始权向量 $\mathbf{w}(1)$ 的值可任选，显然这就是前面所说的感知器算法，因此感知器算法是梯度法的一个特例。在上式中 C 是预先选好的固定值，在迭代过程中，只要 $\mathbf{w}^T \mathbf{x}^k \leq 0$ ，就要对权向量修正 $C\mathbf{x}^k$ 值，因此称为固定增量算法。

● 分类器的不等式方程

求两类问题的解相当于求一组线性不等式的解，因此，若给出分别属于 ω_1 和 ω_2 的两个模式样本的训练样本集，即可求出其权向量 \mathbf{w} 的解，其性质应满足：

$$\begin{aligned}\mathbf{w}^T \mathbf{x} &> 0, \forall \mathbf{x} \in \omega_1 \\ \mathbf{w}^T \mathbf{x} &< 0, \forall \mathbf{x} \in \omega_2\end{aligned}$$

将属于 ω_2 的模式乘以 (-1) ，可得对于全部模式都有 $\mathbf{w}^T \mathbf{x} > 0$ 的条件。

设两类模式的训练样本总数为 N ，写成增广形式，则有不等式组：

$$\mathbf{X}\mathbf{w} > \mathbf{0}$$

式中：

$$\mathbf{X} = \begin{pmatrix} (\mathbf{x}^1)^T \\ \vdots \\ (\mathbf{x}^i)^T \\ -(\mathbf{x}^{i+1})^T \\ \vdots \\ -(\mathbf{x}^N)^T \end{pmatrix}, \begin{pmatrix} (\mathbf{x}^1)^T \\ \vdots \\ (\mathbf{x}^i)^T \end{pmatrix} \in \omega_1, \begin{pmatrix} (\mathbf{x}^{i+1})^T \\ \vdots \\ (\mathbf{x}^N)^T \end{pmatrix} \in \omega_2$$

$$\mathbf{w} = (w_1, w_2, \dots, w_n, w_{n+1})^T$$

其中， $\mathbf{0}$ 是零向量， $(\mathbf{x}^i)^T$ 是第 i 个 n 维模式样本的增广向量，即 $(\mathbf{x}^i)^T = (x_{i_1}, x_{i_2}, \dots, x_{i_n}, 1)^T, i = 1, 2, \dots, N$ ，它包括分属于 ω_1 和 ω_2 中全部供训练用的样本，但属于 ω_2 类的模式应乘以 (-1) ，所以 \mathbf{X} 是一个 $N \times (n+1)$ 阶的矩阵。

● H-K 算法

H-K 算法是求解 $\mathbf{X}\mathbf{w}=\mathbf{b}$ ，式中 $\mathbf{b}=(b_1, b_2, \dots, b_N)^T$ ， \mathbf{b} 的所有分量都是正值。这里要同时计算 \mathbf{w} 和 \mathbf{b} ，我们已知 \mathbf{X} 不是 $N*N$ 的方阵，通常是行多于列的 $N*(n+1)$ 阶的长方形，属于超定方程，因此一般情况下， $\mathbf{X}\mathbf{w}=\mathbf{b}$ 没有唯一确定解，但可求其线性最小二乘解。

设 $\mathbf{X}\mathbf{w}=\mathbf{b}$ 的线性最小二乘解为 \mathbf{w}^* ，即使 $\|\mathbf{X}\mathbf{w}^*-\mathbf{b}\|$ 极小

采用梯度法，定义准则函数：

$$J(\mathbf{w}, \mathbf{x}, \mathbf{b}) = \frac{1}{2} \sum_{i=1}^N (\mathbf{w}^T \mathbf{x}_i - b_i)^2 = \frac{1}{2} \|\mathbf{w}^T \mathbf{x}_i - b_i\|^2 = \frac{1}{2} (\mathbf{X}\mathbf{w} - \mathbf{b})^T (\mathbf{X}\mathbf{w} - \mathbf{b})$$

当 $\mathbf{X}\mathbf{w}=\mathbf{b}$ 的条件满足时， J 达到最小值。由于上式中包括的 $\sum_{i=1}^N (\mathbf{w}^T \mathbf{x}_i - b_i)^2$ 项为两个数量方差的和，且我们将使其最小化，因此也称之为最小均方误差算法。

使函数 J 同时对变量 \mathbf{w} 和 \mathbf{b} 求最小。对于 \mathbf{w} 的梯度为：

$$\frac{\partial J}{\partial \mathbf{w}} = \mathbf{X}^T (\mathbf{X}\mathbf{w} - \mathbf{b})$$

使 $\frac{\partial J}{\partial \mathbf{w}} = 0$ ，得 $\mathbf{X}^T (\mathbf{X}\mathbf{w} - \mathbf{b}) = 0$ ，从而 $\mathbf{X}^T \mathbf{X}\mathbf{w} = \mathbf{X}^T \mathbf{b}$ 。因为 $\mathbf{X}^T \mathbf{X}$ 为 $(n+1)*(n+1)$ 阶方阵，因此可求得解：

$$\mathbf{w} = (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T \mathbf{b} = \mathbf{X}^\# \mathbf{b}$$

这里 $\mathbf{X}^\# = (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T$ 称为 \mathbf{X} 的伪逆， \mathbf{X} 是 $N*(n+1)$ 阶的长方形。

由上式可知，只要求出 \mathbf{b} 即可求得 \mathbf{w} 。利用梯度法可求得 \mathbf{b} 的迭代公式为：

$$\mathbf{b}(k+1) = \mathbf{b}(k) - C \cdot \left(\frac{\partial J}{\partial \mathbf{b}} \right)_{\mathbf{b}=\mathbf{b}(k)}$$

根据上述约束条件，在每次迭代中， $\mathbf{b}(k)$ 的全部分量只能是正值。

由 J 的准则函数式, J 也是正值, 因此, 当取校正增量 C 为正值时, 为保证每次迭代中的 $\mathbf{b}(k)$ 都是正值, 应使 $\left(\frac{\partial J}{\partial \mathbf{b}}\right)_{\mathbf{b}=\mathbf{b}(k)}$ 为非正值。在此条件下, 准则函数 J 的微分为:

$$-2\left(\frac{\partial J}{\partial \mathbf{b}}\right)_{\mathbf{b}=\mathbf{b}(k)} = (\mathbf{X}\mathbf{w} - \mathbf{b}) + |\mathbf{X}\mathbf{w} - \mathbf{b}|$$

该式满足以下条件:

$$\text{若 } [\mathbf{X}\mathbf{w}(k) - \mathbf{b}(k)] > 0, \text{ 则 } -\left(\frac{\partial J}{\partial \mathbf{b}}\right)_{\mathbf{b}=\mathbf{b}(k)} = \mathbf{X}\mathbf{w}(k) - \mathbf{b}(k).$$

$$\text{若 } [\mathbf{X}\mathbf{w}(k) - \mathbf{b}(k)] < 0, \text{ 则 } -\left(\frac{\partial J}{\partial \mathbf{b}}\right)_{\mathbf{b}=\mathbf{b}(k)} = 0$$

由 \mathbf{b} 的迭代式和微分, 有:

$$\mathbf{b}(k+1) = \mathbf{b}(k) + \delta \mathbf{b}(k)$$

$$\delta \mathbf{b}(k) = C[\mathbf{X}\mathbf{w}(k) - \mathbf{b}(k) + |\mathbf{X}\mathbf{w}(k) - \mathbf{b}(k)|]$$

将此式代入 $\mathbf{w} = \mathbf{X}^\# \mathbf{b}$, 有:

$$\mathbf{w}(k+1) = \mathbf{X}^\# \mathbf{b}(k+1) = \mathbf{X}^\# [\mathbf{b}(k) + \delta \mathbf{b}(k)] = \mathbf{w}(k) + \mathbf{X}^\# \delta \mathbf{b}(k)$$

为简化起见, 令 $\mathbf{e}(k) = \mathbf{X}\mathbf{w}(k) - \mathbf{b}(k)$, 可得 H-K 算法的迭代式。

设初值为 $\mathbf{b}(1)$, 其每一分量均为正值, 则:

$$\mathbf{w}(1) = \mathbf{X}^\# \mathbf{b}(1)$$

$$\mathbf{e}(k) = \mathbf{X}\mathbf{w}(k) - \mathbf{b}(k)$$

$$\begin{aligned} \mathbf{w}(k+1) &= \mathbf{w}(k) + \mathbf{X}^\# \{C[\mathbf{X}\mathbf{w}(k) - \mathbf{b}(k) + |\mathbf{X}\mathbf{w}(k) - \mathbf{b}(k)|]\} \\ &= \mathbf{w}(k) + C\mathbf{X}^\# [\mathbf{e}(k) + |\mathbf{e}(k)|] \end{aligned}$$

由于

$$\mathbf{X}^\# \mathbf{e}(k) = \mathbf{X}^\# [\mathbf{X}\mathbf{w}(k) - \mathbf{b}(k)] = (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T [\mathbf{X}\mathbf{w}(k) - \mathbf{b}(k)]$$

$$= \mathbf{w}(k) - \mathbf{X}^\# \mathbf{b}(k) = 0$$

因此

$$\mathbf{w}(k+1) = \mathbf{w}(k) + C\mathbf{X}^\# |\mathbf{e}(k)|$$

$$\begin{aligned} \mathbf{b}(k+1) &= \mathbf{b}(k) + C[\mathbf{X}\mathbf{w}(k) - \mathbf{b}(k) + |\mathbf{X}\mathbf{w}(k) - \mathbf{b}(k)|] \\ &= \mathbf{b}(k) + C[\mathbf{e}(k) + |\mathbf{e}(k)|] \end{aligned}$$

- 模式类别可分性的判别

当不等式组 $\mathbf{X}\mathbf{w} > \mathbf{0}$ 有解时，该算法对 $0 < C \leq 1$ 收敛，可求得解 \mathbf{w} 。

(i) 若 $\mathbf{e}(k)=0$ ，即 $\mathbf{X}\mathbf{w}(k)=\mathbf{b}(k)>0$ ，有解。

(ii) 若 $\mathbf{e}(k)>0$ ，此时隐含 $\mathbf{X}\mathbf{w}(k) \geq \mathbf{b}(k)>0$ 的条件，有解。若继续进行迭代，可使 $\mathbf{e}(k)=0$ 。

(iii) 若 $\mathbf{e}(k)$ 的全分量停止变为正值（但不是全部为零），表明该模式类别线性不可分。因此，若 $\mathbf{e}(k)$ 没有一个分量为正值，则 $\mathbf{b}(k)$ 不会再变化，所以不能求得解。

● LMSE 算法实例：有解情况

已知模式样本集： $\omega_1: \{(0\ 0)^T, (0\ 1)^T\}$, $\omega_2: \{(1\ 0)^T, (1\ 1)^T\}$

模式的增广矩阵 X 为：
$$X = \begin{pmatrix} 0 & 0 & 1 \\ 0 & 1 & 1 \\ -1 & 0 & -1 \\ -1 & -1 & -1 \end{pmatrix}$$

其伪逆矩阵为：
$$X^\# = (X^T X)^{-1} X^T = \frac{1}{2} \begin{pmatrix} -1 & -1 & -1 & -1 \\ -1 & 1 & 1 & -1 \\ \frac{3}{2} & \frac{1}{2} & -\frac{1}{2} & \frac{1}{2} \end{pmatrix}$$

取 $\mathbf{b}(1) = (1\ 1\ 1\ 1)^T$ 和 $C=1$ ，由 H-K 算法的迭代式：

$$\mathbf{w}(1) = X^\# \mathbf{b}(1) = (-2\ 0\ 1)^T$$

因 $X\mathbf{w}(1) = (1\ 1\ 1\ 1)^T$ ，即 $\mathbf{e}(1) = X\mathbf{w}(1) - \mathbf{b}(1) = (0\ 0\ 0\ 0)^T$ ，故 $\mathbf{w}(1)$ 是解。

● LMSE 算法实例：无解情况

已知模式样本集： $\omega_1: \{(0\ 0)^T, (1\ 1)^T\}$, $\omega_2: \{(0\ 1)^T, (1\ 0)^T\}$

模式的增广矩阵 X 为：
$$X = \begin{pmatrix} 0 & 0 & 1 \\ 1 & 1 & 1 \\ 0 & -1 & -1 \\ -1 & 0 & -1 \end{pmatrix}$$

其伪逆矩阵为：
$$X^\# = (X^T X)^{-1} X^T = \frac{1}{2} \begin{pmatrix} -1 & 1 & 1 & -1 \\ -1 & 1 & -1 & 1 \\ \frac{3}{2} & -\frac{1}{2} & -\frac{1}{2} & -\frac{1}{2} \end{pmatrix}$$

取 $\mathbf{b}(1) = (1\ 1\ 1\ 1)^T$ 和 $C=1$ ，由 H-K 算法的迭代式：

$$\mathbf{w}(1) = X^\# \mathbf{b}(1) = (0\ 0\ 0)^T$$

则： $\mathbf{e}(1) = X\mathbf{w}(1) - \mathbf{b}(1) = (-1\ -1\ -1\ -1)^T$ ，全部分量均为负，无解。

- 判别函数产生逐步分析

设初始势函数 $K_0(x) = 0$

第一步：加入第一个训练样本 \mathbf{x}^1 ，则有

$$K_1(\mathbf{x}) = \begin{cases} K(\mathbf{x}, \mathbf{x}^1) & \text{if } \mathbf{x}^1 \in \omega_1 \\ -K(\mathbf{x}, \mathbf{x}^1) & \text{if } \mathbf{x}^1 \in \omega_2 \end{cases}$$

这里第一步积累势函数 $K_1(\mathbf{x})$ 描述了加入第一个样本时的边界划分。当样本属于 ω_1 时，势函数为正；当样本属于 ω_2 时，势函数为负。

第二步：加入第二个训练样本 \mathbf{x}^2 ，则有

(i) 若 $\mathbf{x}^2 \in \omega_1$ 且 $K_1(\mathbf{x}^2) > 0$ ，或 $\mathbf{x}^2 \in \omega_2$ 且 $K_1(\mathbf{x}^2) < 0$ ，则分类正确，此时 $K_2(\mathbf{x}) = K_1(\mathbf{x})$ ，即积累势函数不变。

(ii) 若 $\mathbf{x}^2 \in \omega_1$ 且 $K_1(\mathbf{x}^2) < 0$ ，则

$$K_2(\mathbf{x}) = K_1(\mathbf{x}) + K(\mathbf{x}, \mathbf{x}^2) = \pm K(\mathbf{x}, \mathbf{x}^1) + K(\mathbf{x}, \mathbf{x}^2)$$

(iii) 若 $\mathbf{x}^2 \in \omega_2$ 且 $K_1(\mathbf{x}^2) > 0$ ，则

$$K_2(\mathbf{x}) = K_1(\mathbf{x}) - K(\mathbf{x}, \mathbf{x}^2) = \pm K(\mathbf{x}, \mathbf{x}^1) - K(\mathbf{x}, \mathbf{x}^2)$$

以上 (ii)、(iii) 两种情况属于错分。假如 \mathbf{x}^2 处于 $K_1(\mathbf{x})$ 定义的边界的错误一侧，则当 $\mathbf{x}^2 \in \omega_1$ 时，积累位势 $K_2(\mathbf{x})$ 要加 $K(\mathbf{x}, \mathbf{x}^2)$ ，当 $\mathbf{x}^2 \in \omega_2$ 时，积累位势 $K_2(\mathbf{x})$ 要减 $K(\mathbf{x}, \mathbf{x}^2)$ 。

第 K 步：设 $K_k(\mathbf{x})$ 为加入训练样本 $\mathbf{x}^1, \mathbf{x}^2, \dots, \mathbf{x}^k$ 后的积累位势，则加入第 (k+1) 个样本时， $K_{k+1}(\mathbf{x})$ 决定如下：

(i) 若 $\mathbf{x}^{k+1} \in \omega_1$ 且 $K_k(\mathbf{x}^{k+1}) > 0$ ，或 $\mathbf{x}^{k+1} \in \omega_2$ 且 $K_k(\mathbf{x}^{k+1}) < 0$ ，则分类正确，此时 $K_{k+1}(\mathbf{x}) = K_k(\mathbf{x})$ ，即积累位势不变。

(ii) 若 $\mathbf{x}^{k+1} \in \omega_1$ 且 $K_k(\mathbf{x}^{k+1}) < 0$ ，则 $K_{k+1}(\mathbf{x}) = K_k(\mathbf{x}) + K(\mathbf{x}, \mathbf{x}^{k+1})$

(iii) 若 $\mathbf{x}^{k+1} \in \omega_2$ 且 $K_k(\mathbf{x}^{k+1}) > 0$ ，则 $K_{k+1}(\mathbf{x}) = K_k(\mathbf{x}) - K(\mathbf{x}, \mathbf{x}^{k+1})$

因此, 积累位势的迭代运算可写成: $K_{k+1}(\mathbf{x}) = K_k(\mathbf{x}) + r_{k+1}K(\mathbf{x}, \mathbf{x}^{k+1})$,

r_{k+1} 为校正系数:

$$r_{k+1} = \begin{cases} 0 & \text{if } \mathbf{x}^{k+1} \in \omega_1 \text{ and } K_k(\mathbf{x}^{k+1}) > 0 \\ 0 & \text{if } \mathbf{x}^{k+1} \in \omega_2 \text{ and } K_k(\mathbf{x}^{k+1}) < 0 \\ 1 & \text{if } \mathbf{x}^{k+1} \in \omega_1 \text{ and } K_k(\mathbf{x}^{k+1}) < 0 \\ -1 & \text{if } \mathbf{x}^{k+1} \in \omega_2 \text{ and } K_k(\mathbf{x}^{k+1}) > 0 \end{cases}$$

若从给定的训练样本集 $\{\mathbf{x}^1, \mathbf{x}^2, \dots, \mathbf{x}^k, \dots\}$ 中去除不使积累位势发生变化的样本, 即使 $K_j(\mathbf{x}^{j+1}) > 0$ 且 $\mathbf{x}^{j+1} \in \omega_1$, 或 $K_j(\mathbf{x}^{j+1}) < 0$ 且 $\mathbf{x}^{j+1} \in \omega_2$ 的那些样本, 则可得一简化的样本序列 $\{\hat{\mathbf{x}}^1, \hat{\mathbf{x}}^2, \dots, \hat{\mathbf{x}}^j, \dots\}$, 它们完全是校正错误的样本。此时, 上述迭代公式可归纳为:

$$K_{k+1}(\mathbf{x}) = \sum_{\hat{\mathbf{x}}^j} a_j K(\mathbf{x}, \hat{\mathbf{x}}^j)$$

其中

$$a_j = \begin{cases} +1 & \text{for } \hat{\mathbf{x}}^j \in \omega_1 \\ -1 & \text{for } \hat{\mathbf{x}}^j \in \omega_2 \end{cases}$$

也就是说, 由 $k+1$ 个训练样本产生的积累位势, 等于 ω_1 类和 ω_2 类两者中的校正错误样本的总位势之差。

● 构成势函数的两种方式

第一类势函数：可用对称的有限多项式展开，即：

$$K(\mathbf{x}, \mathbf{x}_k) = \sum_{i=1}^m \varphi_i(\mathbf{x}) \varphi_i(\mathbf{x}_k)$$

其中 $\{\varphi_i(\mathbf{x})\}$ 在模式定义域内为正交函数集。将这类势函数代入判别函数，有：

$$\begin{aligned} d_{k+1}(\mathbf{x}) &= d_k(\mathbf{x}) + r_{k+1} \sum_{i=1}^m \varphi_i(\mathbf{x}_{k+1}) \varphi_i(\mathbf{x}) \\ &= d_k(\mathbf{x}) + \sum_{i=1}^m r_{k+1} \varphi_i(\mathbf{x}_{k+1}) \varphi_i(\mathbf{x}) \end{aligned}$$

得迭代关系：

$$d_{k+1}(\mathbf{x}) = \sum_{i=1}^m C_i(k+1) \varphi_i(\mathbf{x})$$

其中

$$C_i(k+1) = C_i(k) + r_{k+1} \varphi_i(\mathbf{x}_{k+1})$$

因此，积累位势可写成：

$$K_{k+1}(\mathbf{x}) = \sum_{i=1}^m C_i(k+1) \varphi_i(\mathbf{x}), \quad C_i \text{ 可用迭代式求得。}$$



第二类势函数：选择双变量 \mathbf{x} 和 \mathbf{x}_k 的对称函数作为势函数，即 $K(\mathbf{x}, \mathbf{x}_k)$

$= K(\mathbf{x}_k, \mathbf{x})$ ，并且它可展开成无穷级数，例如：

$$(a) \quad K(\mathbf{x}, \mathbf{x}_k) = e^{-\alpha \|\mathbf{x} - \mathbf{x}_k\|^2}$$

$$(b) \quad K(\mathbf{x}, \mathbf{x}_k) = \frac{1}{1 + \alpha \|\mathbf{x} - \mathbf{x}_k\|^2}, \quad \alpha \text{ 是正常数}$$

$$(c) \quad K(\mathbf{x}, \mathbf{x}_k) = \frac{\sin \alpha \|\mathbf{x} - \mathbf{x}_k\|^2}{\alpha \|\mathbf{x} - \mathbf{x}_k\|^2}$$



● 势函数法

实例 1：用第一类势函数的算法进行分类

(1) 选择合适的正交函数集 $\{\varphi_i(\mathbf{x})\}$

选择 Hermite 多项式，其正交域为 $(-\infty, +\infty)$ ，其一维形式是

$$\varphi_k = \frac{e^{-x^2/2}}{\sqrt{2^k \cdot k! \sqrt{\pi}}} H_k(x), \quad k = 0, 1, 2, \dots$$

$$H_n(x) = (-1)^n e^{x^2} \frac{d^n}{dx^n} e^{-x^2}$$

$$\text{其正交性: } \int_{-\infty}^{+\infty} H_m(x) H_n(x) e^{-x^2} dx = \begin{cases} 0 & m \neq n \\ 2^n n! \sqrt{\pi} & m = n \end{cases}$$

其中， $H_k(\mathbf{x})$ 前面的乘式为正交归一化因子，为计算简便可省略。因此，Hermite 多项式前面几项的表达式为

$$H_0(x)=1, \quad H_1(x)=2x, \quad H_2(x)=4x^2-2,$$

$$H_3(x)=8x^3-12x, \quad H_4(x)=16x^4-48x^2+12$$

(2) 建立二维的正交函数集

二维的正交函数集可由任意一对一维的正交函数组成，这里取四项最低阶的二维的正交函数

$$\varphi_1(\mathbf{x}) = \varphi_1(x_1, x_2) = H_0(x_1)H_0(x_2) = 1$$

$$\varphi_2(\mathbf{x}) = \varphi_2(x_1, x_2) = H_1(x_1)H_0(x_2) = 2x_1$$

$$\varphi_3(\mathbf{x}) = \varphi_3(x_1, x_2) = H_0(x_1)H_1(x_2) = 2x_2$$

$$\varphi_4(\mathbf{x}) = \varphi_4(x_1, x_2) = H_1(x_1)H_1(x_2) = 4x_1x_2$$

(3) 生成势函数

按第一类势函数定义，得到势函数

$$K(\mathbf{x}, \mathbf{x}_k) = \sum_{i=1}^4 \varphi_i(\mathbf{x})\varphi_i(\mathbf{x}_k) = 1 + 4x_1x_{k_1} + 4x_2x_{k_2} + 16x_1x_2x_{k_1}x_{k_2}$$

其中 $\mathbf{x} = (x_1, x_2)^T, \mathbf{x}_k = (x_{k_1}, x_{k_2})^T$

(4) 通过训练样本逐步计算累积位势 $K(x)$

给定训练样本: ω_1 类为 $\mathbf{x}^1 = (1 \ 0)^T, \mathbf{x}^2 = (0 \ -1)^T$

ω_2 类为 $\mathbf{x}^3 = (-1 \ 0)^T, \mathbf{x}^4 = (0 \ 1)^T$

累积位势 $K(x)$ 的迭代算法如下

第一步: 取 $\mathbf{x}^1 = (1 \ 0)^T \in \omega_1$, 故

$$K_1(\mathbf{x}) = K(\mathbf{x}, \mathbf{x}^1) = 1 + 4x_1 \cdot 1 + 4x_2 \cdot 0 + 16x_1x_2 \cdot 1 \cdot 0 = 1 + 4x_1$$

第二步: 取 $\mathbf{x}^2 = (0 \ -1)^T \in \omega_1$, 故 $K_1(\mathbf{x}^2) = 1 + 4 \cdot 0 = 1$

因 $K_1(\mathbf{x}^2) > 0$ 且 $\mathbf{x}^2 \in \omega_1$, 故 $K_2(\mathbf{x}) = K_1(\mathbf{x}) = 1 + 4x_1$

第三步: 取 $\mathbf{x}^3 = (-1 \ 0)^T \in \omega_2$, 故 $K_2(\mathbf{x}^3) = 1 + 4 \cdot (-1) = -3$

因 $K_2(\mathbf{x}^3) < 0$ 且 $\mathbf{x}^3 \in \omega_2$, 故 $K_3(\mathbf{x}) = K_2(\mathbf{x}) = 1 + 4x_1$

第四步: 取 $\mathbf{x}^4 = (0 \ 1)^T \in \omega_2$, 故 $K_3(\mathbf{x}^4) = 1 + 4 \cdot 0 = 1$

因 $K_3(\mathbf{x}^4) > 0$ 且 $\mathbf{x}^4 \in \omega_2$,

$$\text{故 } K_4(\mathbf{x}) = K_3(\mathbf{x}) - K(\mathbf{x}, \mathbf{x}^4) = 1 + 4x_1 - (1 + 4x_2) = 4x_1 - 4x_2$$

将全部训练样本重复迭代一次, 得

第五步: 取 $\mathbf{x}^5 = \mathbf{x}^1 = (1 \ 0)^T \in \omega_1$, $K_4(\mathbf{x}^5) = 4$

$$\text{故 } K_5(\mathbf{x}) = K_4(\mathbf{x}) = 4x_1 - 4x_2$$

第六步: 取 $\mathbf{x}^6 = \mathbf{x}^2 = (0 \ -1)^T \in \omega_1$, $K_5(\mathbf{x}^6) = 4$

$$\text{故 } K_6(\mathbf{x}) = K_5(\mathbf{x}) = 4x_1 - 4x_2$$

第七步: 取 $\mathbf{x}^7 = \mathbf{x}^3 = (-1 \ 0)^T \in \omega_2$, $K_6(\mathbf{x}^7) = -4$

$$\text{故 } K_7(\mathbf{x}) = K_6(\mathbf{x}) = 4x_1 - 4x_2$$

第八步：取 $\mathbf{x}^8 = \mathbf{x}^4 = (0 \ 1)^T \in \omega_2$, $K_7(\mathbf{x}^8) = -4$

$$\text{故 } K_8(\mathbf{x}) = K_7(\mathbf{x}) = 4x_1 - 4x_2$$

以上对全部训练样本都能正确分类，因此算法收敛于判别函数

$$d(\mathbf{x}) = 4x_1 - 4x_2$$

- 势函数法

实例 2：用第二类势函数的算法进行分类

选择指数型势函数，取 $\alpha=1$ ，在二维情况下势函数为

$$K(x, x_k) = e^{-\|x - x_k\|^2} = e^{-[(x_1 - x_{k1})^2 + (x_2 - x_{k2})^2]}$$

这里： ω_1 类为 $\mathbf{x}^1 = (0 \ 0)^T$, $\mathbf{x}^2 = (2 \ 0)^T$

ω_2 类为 $\mathbf{x}^3 = (1 \ 1)^T$, $\mathbf{x}^4 = (1 \ -1)^T$

可以看出，这两类模式是线性不可分的。算法步骤如下：

第一步：取 $\mathbf{x}^1 = (0 \ 0)^T \in \omega_1$ ，则

$$K_1(\mathbf{x}) = K(\mathbf{x}, \mathbf{x}^1) = e^{-[(x_1 - 0)^2 + (x_2 - 0)^2]} = e^{-(x_1^2 + x_2^2)}$$

第二步：取 $\mathbf{x}^2 = (2 \ 0)^T \in \omega_1$

$$\text{因 } K_1(\mathbf{x}^2) = e^{-(4+0)} = e^{-4} > 0,$$

$$\text{故 } K_2(\mathbf{x}) = K_1(\mathbf{x}) = e^{-(x_1^2 + x_2^2)}$$

第三步：取 $\mathbf{x}^3 = (1 \ 1)^T \in \omega_2$

$$\text{因 } K_2(\mathbf{x}^3) = e^{-(1+1)} = e^{-2} > 0,$$

$$\text{故 } K_3(\mathbf{x}) = K_2(\mathbf{x}) - K(\mathbf{x}, \mathbf{x}^3) = e^{-(x_1^2 + x_2^2)} - e^{-[(x_1 - 1)^2 + (x_2 - 1)^2]}$$

第四步：取 $\mathbf{x}^4 = (1 \ -1)^T \in \omega_2$

$$\text{因 } K_3(\mathbf{x}^4) = e^{-(1+1)} - e^{-(0+4)} = e^{-2} - e^{-4} > 0,$$

$$\text{故 } K_4(\mathbf{x}) = K_3(\mathbf{x}) - K(\mathbf{x}, \mathbf{x}^4)$$

$$= e^{-(x_1^2 + x_2^2)} - e^{-[(x_1 - 1)^2 + (x_2 - 1)^2]} - e^{-[(x_1 - 1)^2 + (x_2 + 1)^2]}$$

需对全部训练样本重复迭代一次

第五步：取 $\mathbf{x}^5 = \mathbf{x}^1 = (0 \ 0)^T \in \omega_1$ ， $K_4(\mathbf{x}^5) = e^0 - e^{-2} - e^{-2} = 1 - 2e^{-2} > 0$

$$\text{故 } K_5(\mathbf{x}) = K_4(\mathbf{x})$$

第六步：取 $\mathbf{x}^6 = \mathbf{x}^2 = (2 \ 0)^T \in \omega_1$, $K_5(\mathbf{x}^6) = e^{-4} - e^{-2} - e^{-2} = e^{-4} - 2e^{-2} < 0$

故 $K_6(\mathbf{x}) = K_5(\mathbf{x}) + K(\mathbf{x}, \mathbf{x}^6)$

$$= e^{-(x_1^2 + x_2^2)} - e^{-[(x_1 - 1)^2 + (x_2 - 1)^2]} - e^{-[(x_1 - 1)^2 + (x_2 + 1)^2]} + e^{-[(x_1 - 2)^2 + x_2^2]}$$

第七步：取 $\mathbf{x}^7 = \mathbf{x}^3 = (1 \ 1)^T \in \omega_2$, $K_6(\mathbf{x}^7) = e^{-2} - e^0 - e^{-4} + e^{-2} = 2e^{-2} - e^{-4} - 1 < 0$

故 $K_7(\mathbf{x}) = K_6(\mathbf{x})$

第八步：取 $\mathbf{x}^8 = \mathbf{x}^4 = (1 \ -1)^T \in \omega_2$, $K_7(\mathbf{x}^8) = e^{-2} - e^{-4} - e^0 + e^{-2} = 2e^{-2} - e^{-4} - 1 < 0$

故 $K_8(\mathbf{x}) = K_7(\mathbf{x})$

第九步：取 $\mathbf{x}^9 = \mathbf{x}^1 = (0 \ 0)^T \in \omega_1$, $K_8(\mathbf{x}^9) = e^0 - e^{-2} - e^{-2} + e^{-4} = 1 + e^{-4} - 2e^{-2} > 0$

故 $K_9(\mathbf{x}) = K_8(\mathbf{x})$

第十步：取 $\mathbf{x}^{10} = \mathbf{x}^2 = (2 \ 0)^T \in \omega_1$, $K_9(\mathbf{x}^{10}) = e^{-4} - e^{-2} - e^{-2} + e^0 = 1 + e^{-4} - 2e^{-2} > 0$

故 $K_{10}(\mathbf{x}) = K_9(\mathbf{x})$

经过上述迭代，全部模式都已正确分类，因此算法收敛于判别函数

$$d(\mathbf{x}) = e^{-(x_1^2 + x_2^2)} - e^{-[(x_1 - 1)^2 + (x_2 - 1)^2]} - e^{-[(x_1 - 1)^2 + (x_2 + 1)^2]} + e^{-[(x_1 - 2)^2 + x_2^2]}$$