

- 点到点之间的距离

在 n 维空间中， \mathbf{a} 与 \mathbf{b} 两点之间的欧氏距离为：

$$D(\mathbf{a}, \mathbf{b}) = \|\mathbf{a} - \mathbf{b}\|$$

写成距离平方：

$$D^2(\mathbf{a}, \mathbf{b}) = (\mathbf{a} - \mathbf{b})^T (\mathbf{a} - \mathbf{b}) = \sum_{k=1}^n (a_k - b_k)^2$$

其中， \mathbf{a} 和 \mathbf{b} 为 n 维向量，其第 k 个分量分别是 a_k 和 b_k 。

- 点到点集之间的距离

在 n 维空间中，点 \mathbf{a} 到点 $\mathbf{x}^{(i)}$ 之间的距离平方为：

$$D^2(\mathbf{a}, \mathbf{x}^{(i)}) = \sum_{k=1}^n (a_k - x_k^{(i)})^2$$

因此，点 \mathbf{a} 到点集 $\{\mathbf{x}^{(i)}\}_{i=1,2,\dots,K}$ 之间的均方距离为：

$$\overline{D^2(\mathbf{a}, \{\mathbf{x}^{(i)}\})} = \frac{1}{K} \sum_{i=1}^K D^2(\mathbf{a}, \mathbf{x}^{(i)}) = \frac{1}{K} \sum_{i=1}^K \left\{ \sum_{k=1}^n (a_k - x_k^{(i)})^2 \right\}$$

- 类内距离

n 维空间中同一类内各模式样本点集 $\{\mathbf{x}^{(i)}\}_{i=1,2,\dots,K}$ ，其内部各点的均方距离为 $\overline{D^2(\{\mathbf{x}^{(j)}\}, \{\mathbf{x}^{(i)}\})}$ ，其中 $i, j = 1, 2, \dots, K, i \neq j$ ，即：

$$\overline{D^2(\{\mathbf{x}^{(j)}\}, \{\mathbf{x}^{(i)}\})} = \frac{1}{K} \sum_{j=1}^K \left[\frac{1}{K-1} \sum_{\substack{i=1 \\ i \neq j}}^K \sum_{k=1}^n (x_k^{(j)} - x_k^{(i)})^2 \right]$$

可证明：

$$\overline{D^2} = 2 \sum_{k=1}^n \sigma_k^2$$

其中 σ_k^2 为 $\{\mathbf{x}^{(i)}\}$ 在第 k 个分量上的无偏方差，即：

$$\sigma_k^2 = \frac{1}{K-1} \sum_{i=1}^K (x_k^{(i)} - \bar{x}_k)^2$$

其中 $\bar{x}_k = \frac{1}{K} \sum_{i=1}^K x_k^{(i)}$ 为 $\{\mathbf{x}^{(i)}\}$ 在第 k 个分量方向上的均值。

[证明作为练习]

- 类内散布矩阵

考虑一类内模式点集 $\{\mathbf{x}^{(i)}\}_{i=1,2,\dots,K}$ ，其类内散布矩阵为：

$$\mathbf{S} = \sum_{i=1}^K \{(\mathbf{x}^{(i)} - \mathbf{m})(\mathbf{x}^{(i)} - \mathbf{m})^T\}$$

其中

$$\mathbf{m} = \frac{1}{K} \sum_{i=1}^K \mathbf{x}^{(i)}$$

对属于同一类的模式样本，类内散布矩阵表示各样本点围绕其均值周围的散布情况。

- 类间距离和类间散布矩阵

在考虑有两个以上的类别，如集合 $\{\mathbf{a}^{(i)}\}$ 和 $\{\mathbf{b}^{(j)}\}$ 时，类间距离对类别的可分性起着重要作用，此时应计算：

$$\overline{D^2(\{\mathbf{a}^{(i)}\}, \{\mathbf{b}^{(j)}\})_{i=1,2,\dots,K_a; j=1,2,\dots,K_b}} \circ$$

为简化起见，常用两类样本各自质心间的距离作为类间距离，并假设两类样本出现的概率相等，则：

$$D^2 = \sum_{k=1}^n (m_{1_k} - m_{2_k})^2$$

其中 \mathbf{m}_1 和 \mathbf{m}_2 为两类模式样本集各自的均值向量， m_{1_k} 和 m_{2_k} 为 \mathbf{m}_1 和 \mathbf{m}_2 的第 k 个分量， n 为维数。

写成矩阵形式： $\mathbf{S}_{b2} = (\mathbf{m}_1 - \mathbf{m}_2)(\mathbf{m}_1 - \mathbf{m}_2)^T$ 为两类模式的类间散布矩阵。

对三个以上的类别，类间散布矩阵常写成：

$$\begin{aligned} \mathbf{S}_b &= \frac{1}{2} \sum_{i=1}^M P(\omega_i) \sum_{j=1}^M P(\omega_j) (\mathbf{m}_i - \mathbf{m}_j)(\mathbf{m}_i - \mathbf{m}_j)^T \\ &= \sum_{i=1}^M P(\omega_i) (\mathbf{m}_i - \mathbf{m}_0)(\mathbf{m}_i - \mathbf{m}_0)^T \\ &\propto \sum_{i=1}^M N_i (\mathbf{m}_i - \mathbf{m}_0)(\mathbf{m}_i - \mathbf{m}_0)^T \end{aligned}$$

其中， \mathbf{m}_0 为多类模式（如共有 M 类）分布的总体均值向量，即：

$$\mathbf{m}_0 = E\{\mathbf{x}\} = \sum_{i=1}^c P(\omega_i) \mathbf{m}_i, \quad \forall \omega_i, i=1,2,\dots,M$$

- 多类模式集散布矩阵

多类情况的类内散布矩阵，可写成各类的类内散布矩阵的先验概率的加权和，即：

$$\mathbf{S}_w = \sum_{i=1}^M P(\omega_i) E\{(\mathbf{x} - \mathbf{m}_i)(\mathbf{x} - \mathbf{m}_i)^T \mid \omega_i\} = \sum_{i=1}^M P(\omega_i) \mathbf{C}_i$$

其中 \mathbf{C}_i 是第 i 类的协方差矩阵。

有时，用多类模式总体分布的散布矩阵来反映其可分性，即：

$$\mathbf{S}_t = E\{(\mathbf{x} - \mathbf{m}_0)(\mathbf{x} - \mathbf{m}_0)^T\}, \quad \mathbf{x} \in \forall \omega_i, i = 1, 2, \dots, M$$

其中， \mathbf{m}_0 为多类模式分布的总体均值向量。

可以证明： $\mathbf{S}_t = \mathbf{S}_w + \mathbf{S}_b$ ，即总体散布矩阵是各类类内散布矩阵与类间散布矩阵之和。

● 对于 ω_i 和 ω_j 两类训练样本的特征选择

例：对于 ω_i 和 ω_j 两类训练样本，假设其均值向量为 \mathbf{m}_i 和 \mathbf{m}_j ，其 k 维方向的分量为 m_{ik} 和 m_{jk} ，方差为 σ_{ik}^2 和 σ_{jk}^2 ，定义可分性准则函数：

$$G_k = \frac{(m_{ik} - m_{jk})^2}{\sigma_{ik}^2 + \sigma_{jk}^2}, \quad k = 1, 2, \dots, n$$

则 G_k 为正值。 G_k 值越大，表示测度值的第 k 个分量对分离 ω_i 和 ω_j 两类越有效。将 $\{G_k, k=1, 2, \dots, n\}$ 按大小排队，选出最大的 m 个对应的测度值作为分类特征，即达到特征选择的目的。

- 一般特征的散布矩阵准则

$$\text{类内: } S_w = \sum_{i=1}^c P(\omega_i) E\{(\mathbf{x} - \mathbf{m}_i)(\mathbf{x} - \mathbf{m}_i)^T \mid \omega_i\}$$

$$\text{类间: } S_b = \sum_{i=1}^c P(\omega_i)(\mathbf{m}_i - \mathbf{m}_0)(\mathbf{m}_i - \mathbf{m}_0)^T$$

直观上，类间离散度越大且类内离散度越小，则可分性越好。因此，可推导出散布矩阵准则采用如下形式：

$$\text{行列式形式: } J_1 = \det(S_w^{-1} S_b) = \prod_i \lambda_i$$

$$\text{迹形式: } J_2 = \text{tr}(S_w^{-1} S_b) = \sum_i \lambda_i$$

其中， λ_i 是矩阵 $S_w^{-1} S_b$ 的特征值。使 J_1 或 J_2 最大的子集可作为选择的分类特征。

- 离散的有限 K-L 展开式的形式设一连续的随机实函数 $\mathbf{x}(t)$, $T_1 \leq t \leq T_2$, 则 $\mathbf{x}(t)$ 可用已知的正交函数集 $\{\varphi_j(t), j=1,2,\dots\}$ 的线性组合来展开, 即:

$$\begin{aligned} x(t) &= a_1\varphi_1(t) + a_2\varphi_2(t) + \dots + a_j\varphi_j(t) + \dots \\ &= \sum_{j=1}^{\infty} a_j\varphi_j(t), \quad T_1 \leq t \leq T_2 \end{aligned} \quad (1)$$

式中, a_j 为展开式的随机系数, $\varphi_j(t)$ 为一连续的正交函数, 它应满足:

$$\int_{T_1}^{T_2} \varphi_n^{(t)} \tilde{\varphi}_m(t) dt = \begin{cases} 1, & \text{if } m = n \\ 0 & \text{if } m \neq n \end{cases}$$

其中 $\tilde{\varphi}_m(t)$ 为 $\varphi_m(t)$ 的共轭复数式。

将上式写成离散的正交函数形式, 使连续随机函数 $\mathbf{x}(t)$ 和连续正交函数 $\varphi_j(t)$ 在区间 $T_1 \leq t \leq T_2$ 内被等间隔采样为 n 个离散点, 即:

$$\begin{aligned} \mathbf{x}(t) &\rightarrow \{x(1), x(2), \dots, x(n)\} \\ \varphi_j(t) &\rightarrow \{\varphi_j(1), \varphi_j(2), \dots, \varphi_j(n)\} \end{aligned}$$

写成向量形式:

$$\begin{aligned} \mathbf{x} &= (x(1), x(2), \dots, x(n))^T \\ \varphi_j &= (\varphi_j(1), \varphi_j(2), \dots, \varphi_j(n))^T, \quad j=1, 2, \dots, n \end{aligned}$$

将式(1)取 n 项近似, 并写成离散展开式:

$$\mathbf{x} = \sum_{j=1}^n a_j \varphi_j = \Phi \mathbf{a}, \quad T_1 \leq t \leq T_2 \quad (2)$$

其中, \mathbf{a} 为展开式中随机系数的向量形式, 即:

$$\mathbf{a} = (a_1, a_2, \dots, a_j, \dots, a_n)^T$$

Φ 为 $n \times n$ 维矩阵, 即:

$$\boldsymbol{\Phi} = (\boldsymbol{\varphi}_1, \boldsymbol{\varphi}_2, \dots, \boldsymbol{\varphi}_n) = \begin{bmatrix} \varphi_1(1) & \varphi_2(1) & \cdots & \varphi_n(1) \\ \varphi_1(2) & \varphi_2(2) & \cdots & \varphi_n(2) \\ \cdots & \cdots & \cdots & \cdots \\ \varphi_1(n) & \varphi_2(n) & \cdots & \varphi_n(n) \end{bmatrix}$$

其中，每一列为正交函数集中的一个函数，小括号内的序号为正交函数的采样点次序。因此， $\boldsymbol{\Phi}$ 实质上是由 $\boldsymbol{\varphi}_j$ 向量组成的正交变换矩阵，它将 \boldsymbol{x} 变换成 \boldsymbol{a} 。

- 正交向量集 $\{\varphi_j\}$ 的确定

设随机向量 \mathbf{x} 的总体自相关矩阵为 $\mathbf{R} = E\{\mathbf{x}\mathbf{x}^T\}$ 。由

$$\mathbf{x} = \sum_{j=1}^n a_j \varphi_j = \Phi \mathbf{a}, \quad T_1 \leq t \leq T_2 \quad (1)$$

将 $\mathbf{x} = \Phi \mathbf{a}$ 代入 $\mathbf{R} = E\{\mathbf{x}\mathbf{x}^T\}$ ，得：

$$\mathbf{R} = E\{\Phi \mathbf{a} \mathbf{a}^T \Phi^T\} = \Phi (E\{\mathbf{a} \mathbf{a}^T\}) \Phi^T$$

要求系数向量 \mathbf{a} 的各个不同分量应统计独立，即应使 $(a_1, a_2, \dots, a_j, \dots, a_n)$ 满足如下关系：

$$E(a_j a_k) = \begin{cases} \lambda_j & \text{if } j = k \\ 0 & \text{if } j \neq k \end{cases}$$

写成矩阵形式，应使： $E\{\mathbf{a} \mathbf{a}^T\} = \mathbf{D}_\lambda$ ，其中 \mathbf{D}_λ 为对角形矩阵，其互相关成分均为 0，即：

$$\mathbf{D}_\lambda = \begin{bmatrix} \lambda_1 & 0 & \dots & \dots & 0 \\ 0 & \ddots & 0 & \dots & 0 \\ 0 & & \lambda_j & & 0 \\ 0 & \dots & 0 & \ddots & 0 \\ 0 & \dots & \dots & 0 & \lambda_n \end{bmatrix}$$

则：

$$\mathbf{R} = \Phi \mathbf{D}_\lambda \Phi^T$$

由于 Φ 中的各个向量 φ_j 都相互归一正交，故有：

$$\mathbf{R} \Phi = \Phi \mathbf{D}_\lambda \Phi^T \Phi = \Phi \mathbf{D}_\lambda$$

其中， φ_j 向量对应为：

$$\mathbf{R}\boldsymbol{\varphi}_j=\lambda_j\boldsymbol{\varphi}_j$$

可以看出， λ_j 是 \mathbf{x} 的自相关矩阵 \mathbf{R} 的特征值， $\boldsymbol{\varphi}_j$ 是对应的特征向量。因为 \mathbf{R} 是实对称矩阵，其不同特征值对应的特征向量应正交，即：

$$\boldsymbol{\varphi}_j^T \boldsymbol{\varphi}_k = \begin{cases} 1 & \text{if } j = k \\ 0 & \text{if } j \neq k \end{cases}$$

由式(1)，K-L 展开式系数应为：

$$\mathbf{a} = \boldsymbol{\Phi}^T \mathbf{x}$$

- K-L 展开式系数的计算步骤

K-L 展开式系数可如下求得：

1. 求随机向量 \mathbf{x} 的自相关矩阵： $\mathbf{R} = \mathbf{E}\{\mathbf{x}\mathbf{x}^T\}$
2. 求出矩阵 \mathbf{R} 的特征值 λ_j 和对应的特征向量 $\boldsymbol{\varphi}_j$, $j = 1, 2, \dots, n$, 得矩阵：

$$\boldsymbol{\Phi} = (\boldsymbol{\varphi}_1, \boldsymbol{\varphi}_2, \dots, \boldsymbol{\varphi}_n)$$

3. 计算展开式系数：

$$\mathbf{a} = \boldsymbol{\Phi}^T \mathbf{x}$$

- 问题：选取变换矩阵 Φ ，使得降维后的新向量在最小均方差条件下接近原来的向量 \mathbf{x}

对于 $\mathbf{x} = \sum_{j=1}^n a_j \boldsymbol{\varphi}_j$ ，现仅取 m 项，对略去的系数项用预先选定的常数 b 代替，此时对 \mathbf{x} 的估计值为：

$$\hat{\mathbf{x}} = \sum_{j=1}^m a_j \boldsymbol{\varphi}_j + \sum_{j=m+1}^n b \boldsymbol{\varphi}_j$$

则产生的误差为：

$$\Delta \mathbf{x} = \mathbf{x} - \hat{\mathbf{x}} = \sum_{j=m+1}^n (a_j - b) \boldsymbol{\varphi}_j$$

则 $\Delta \mathbf{x}$ 的均方误差为：

$$\overline{\varepsilon^2} = E\{\|\Delta \mathbf{x}\|^2\} = \sum_{j=m+1}^n \{E(a_j - b)^2\}$$

要使 $\overline{\varepsilon^2}$ 最小，对 b 的选择应满足：

$$\frac{\partial}{\partial b} [E(a_j - b)^2] = \frac{\partial}{\partial b} [E(a_j^2 - 2a_j b + b^2)] = -2[E(a_j) - b] = 0$$

因此， $b = E[a_j]$ ，即对省略掉的 a 中的分量，应使用它们的数学期望来代替，此时的误差为：

$$\begin{aligned} \overline{\varepsilon^2} &= \sum_{j=m+1}^n E[(a_j - E\{a_j\})^2] = \sum_{j=m+1}^n \boldsymbol{\varphi}_j^T E[(\mathbf{x} - E\{\mathbf{x}\})(\mathbf{x} - E\{\mathbf{x}\})^T] \boldsymbol{\varphi}_j \\ &= \sum_{j=m+1}^n \boldsymbol{\varphi}_j^T \mathbf{C}_x \boldsymbol{\varphi}_j \end{aligned}$$

其中， \mathbf{C}_x 为 \mathbf{x} 的协方差矩阵， $\{\boldsymbol{\varphi}_j\}$ 是正交向量，由拉格朗日法可导出 $\boldsymbol{\varphi}_j$ 为 \mathbf{C}_x 的特征值。

设 λ_j 为 \mathbf{C}_x 的第 j 个特征值， $\boldsymbol{\varphi}_j$ 是与 λ_j 对应的特征向量，则

$$\mathbf{C}_x \boldsymbol{\varphi}_j = \lambda_j \boldsymbol{\varphi}_j$$

由于

$$\boldsymbol{\varphi}_j^T \boldsymbol{\varphi}_j = 1$$

从而

$$\boldsymbol{\varphi}_j^T \mathbf{C}_x \boldsymbol{\varphi}_j = \lambda_j$$


因此

$$\overline{\varepsilon^2} = \sum_{j=m+1}^n \boldsymbol{\varphi}_j^T \mathbf{C}_x \boldsymbol{\varphi}_j = \sum_{j=m+1}^n \lambda_j$$

由此可以看出， λ_j 值越小，误差也越小。

● K-L 变换实例

给定两类模式，其分布如图所示，试用 K-L 变换实现一维的特征提取（假定两类模式出现的概率相等）。



$$P(\omega_1)=P(\omega_2)=0.5, \quad m = 0.5 * \frac{1}{5} \sum_{x^j \in \omega_1} x^j + 0.5 * \frac{1}{5} \sum_{x^j \in \omega_2} x^j = (0, 0)^T$$

符合 K-L 变换进行特征压缩的最佳条件。

因 $P(\omega_1)=P(\omega_2)=0.5$ ，故

$$R = \sum_{i=1}^2 P(\omega_i) E\{xx^T\} = \frac{1}{2} \left[\frac{1}{5} \sum_{x^j \in \omega_1} x^j (x^j)^T \right] + \frac{1}{2} \left[\frac{1}{5} \sum_{x^j \in \omega_2} x^j (x^j)^T \right] = \begin{pmatrix} 25.4 & 25.0 \\ 25.0 & 25.4 \end{pmatrix}$$

解特征值方程 $|R - \lambda I| = 0$ ，求 R 的特征值。

由 $(25.4 - \lambda)^2 - 25.0^2 = 0$ ，得特征值 $\lambda_1 = 50.4$ ， $\lambda_2 = 0.4$

其对应的特征向量可由 $R\varphi_i = \lambda_i \varphi_i$ 求得：

$$\varphi_1 = \frac{1}{\sqrt{2}} \begin{pmatrix} 1 \\ 1 \end{pmatrix}, \quad \varphi_2 = \frac{1}{\sqrt{2}} \begin{pmatrix} 1 \\ -1 \end{pmatrix}$$

选 λ_l 对应的变换向量作为变换矩阵，由 $\mathbf{y}=\boldsymbol{\Phi}^T\mathbf{x}$ 得变换后的一维模式特征为：

$$\omega_1:\left\{-\frac{10}{\sqrt{2}},-\frac{9}{\sqrt{2}},-\frac{9}{\sqrt{2}},-\frac{11}{\sqrt{2}},-\frac{11}{\sqrt{2}}\right\} \quad \omega_2:\left\{\frac{10}{\sqrt{2}},\frac{11}{\sqrt{2}},\frac{11}{\sqrt{2}},\frac{9}{\sqrt{2}},\frac{9}{\sqrt{2}}\right\}$$